S3 3 Wrap Up Stats de Base

Table of contents

1 Description des jeux de données

Plusieurs fonctions disponibles sur R :

- `str()` : structure d'un objet R
- `describe()` du package `Hmisc` : description sommaire d'un jeu de données
- `summary()` : résumé statistique d'un jeu de données

Exprimer un jeu de données :

- Moyenne : mieux que médiane pour Bruno Falissard
- Écart-type : contient les 2/3 des données

2 Graphiques

C'est la révolution des graphiques avec les téléphones, les selfies, Instagram !!!

- R Graph Gallery
- Python Graph Gallery

2.A ggplot2

Langage à part entière dans R pour faire des graphiques
Références :

- Site officiel ggplot2
- Blog juba
- Blog larmarange
- R for Data Science - Data Visualization

2.B tidyverse

Collection de packages R pour la science des données
Contient :

- `ggplot2` : graphiques
- `dplyr` : manipulation de données
- `tidyr` : nettoyage de données
- `readr` : lecture de données
- `purrr` : programmation fonctionnelle
- `tibble` : tableaux de données

Références :

- Site officiel tidyverse
- Git tidyverse
- Blog juba
- Blog larmarange

3 Quantifier la force d'une association

3.A OR / RR

- OR : Odds Ratio
- RR : Risque Relatif

3.A.1 Méthode de calcul :

- $$OR = \frac{a/b}{c/d} = \frac{a \times d}{b \times c}$$
- $$RR = \frac{a/(a+b)}{c/(c+d)}$$

OR : bon estimateur du RR lorsque l'événement est rare (< 10 %)

3.B Coefficient de corrélation

= sert à quantifier l'association entre deux variables quantitatives

- Coefficient de corrélation de Pearson : mesure l'association linéaire entre deux variables quantitatives
- Coefficient de corrélation de Spearman : mesure l'association non linéaire entre deux variables quantitatives

NB : association non linéaire : c'est à dire que la distribution des variables n'est pas normale

3.B.1 Exemple :

2 variables :

- `smp$duree.peine` : variable quantitative de distribution non normale (très asymétrique)

```
hist(smp$duree.peine, xlab="Durée de peine", ylab="Fréquence", col="white", cex.axis=1.2, cex.l
box()
```

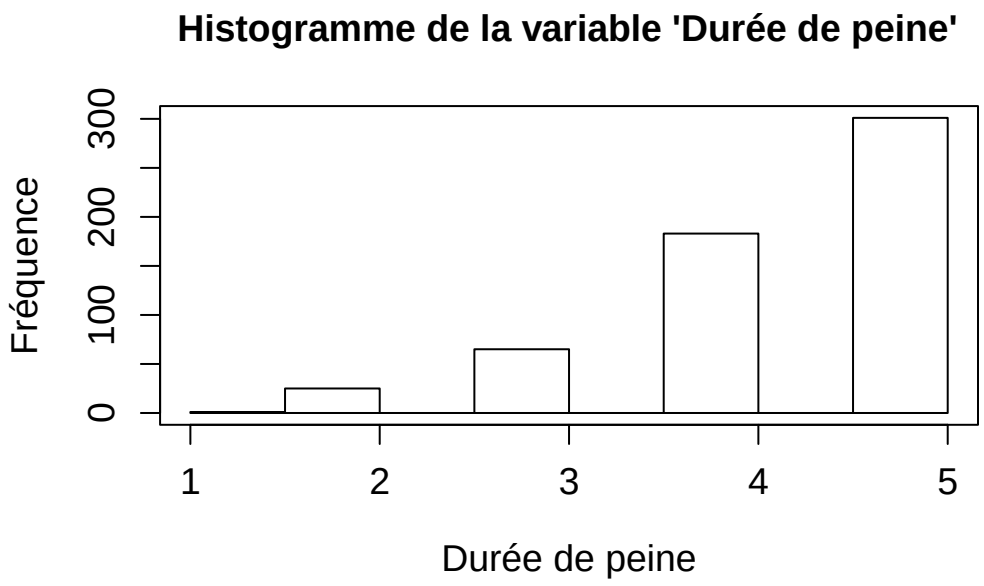


```
qqnorm(smp$duree.peine)
qqline(smp$duree.peine)
```

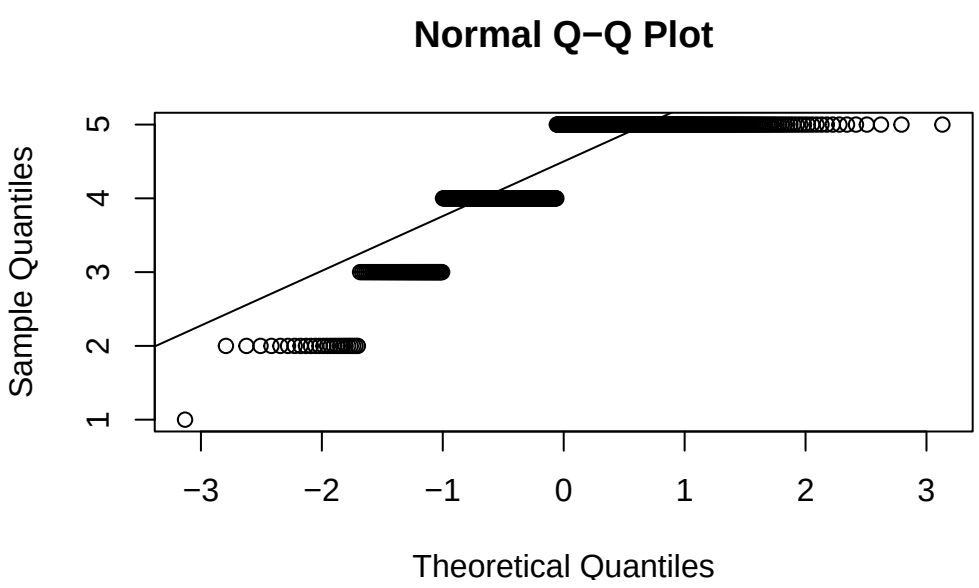

- `smp$age` : variable quantitative de distribution normale

```
hist(smp$age, xlab="Âge", ylab="Fréquence", col="white", cex.axis=1.2, cex.lab=1.2, main="Histo
box()
```

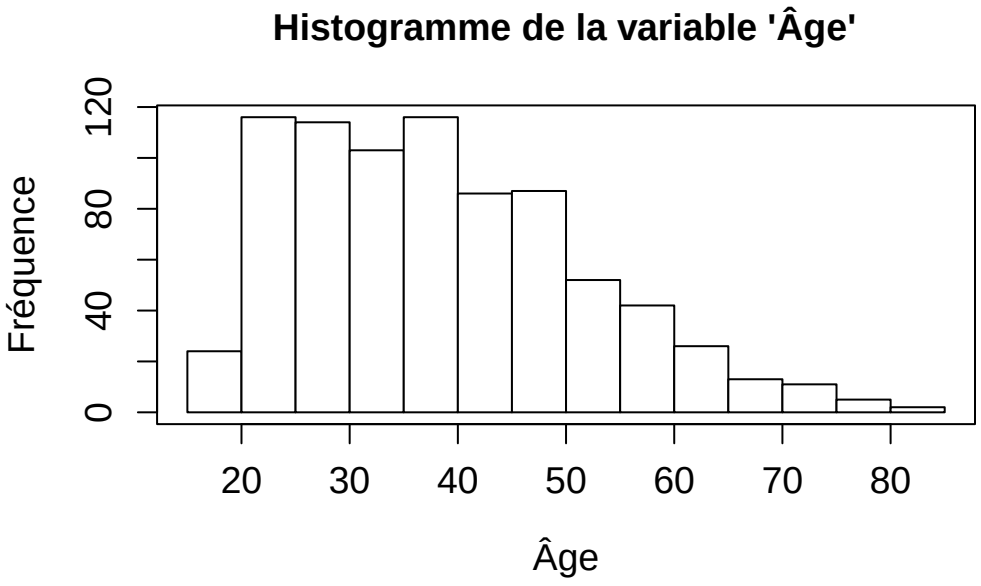


```
qqnorm(smp$age)
qqline(smp$age)
```

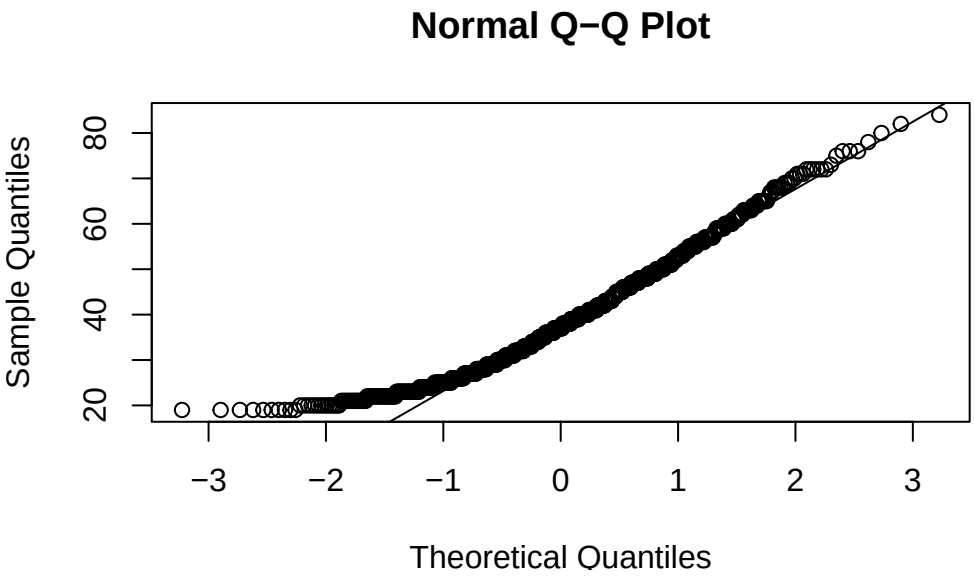

Calcul de la corrélation entre Âge et Durée de peine

Quel coefficient utiliser ?

- **Pearson** : calcule la corrélation linéaire entre deux variables quantitatives
- **Spearman** : calcule la corrélation entre LES RANGS de deux variables quantitatives

Ici : on fait ce qu'on veut selon Bruno Falissard, MÊME SI AUCUNE DES DEUX VARIABLES NE SUIT UNE LOI NORMALE.

Normalité : **nécessaire si on veut TESTER la nullité de corrélation**.

Dans l'exemple de Bruno Falissard, malgré qu'aucune des deux variables ne suive une loi normale, il utilise le coefficient de corrélation de Pearson.

Représentation graphique de la corrélation et de la relation linéaire entre les deux variables :

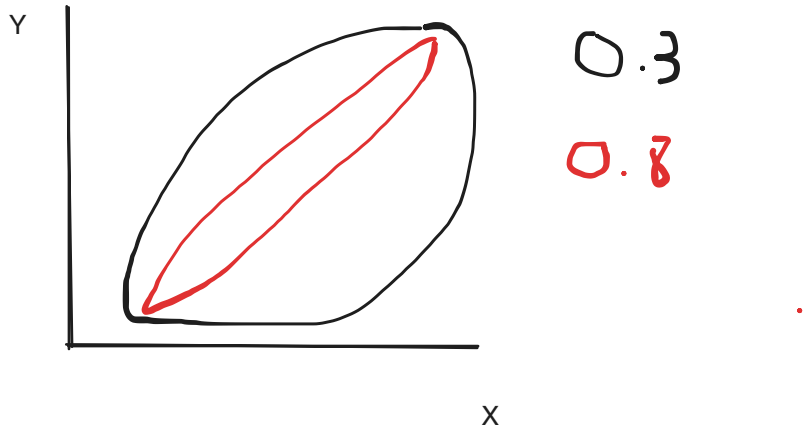

4 Tests statistiques

Petite complexité : quel test utiliser selon le type de variables que l'on veut comparer ?

Grosse complexité : interprétation !

4.A Chi2

- Comparaison de pourcentage (comparaison de deux variables qualitatives)
- Conditions d'application : Effectifs théoriques >= 5 dans chaque case du tableau de contingenceDans une variable binaire (probabilité théorique p) :
- $np \quad 5$
- $n(1 - p) \quad 5$

Cela signifie que chaque catégorie doit avoir **au moins 5 observations attendues**.

De façon générale (tableaux > 2×2) : **toutes les cases doivent avoir un effectif attendu ≥ 5**

4.B Test T de Student

- Comparaison de moyennes (comparaison de deux variables quantitatives)
- Conditions d'application :
  - Variances égales entre les deux groupes
  - ET
    - N > 30 dans chaque groupe et variances égales
    - OU les deux distributions sont normales

En fait : + les distributions s'éloignent de la normalité, + il faut un grand échantillon pour appliquer le test T de Student.

“On ne peut pas être rigoureux avec les conditions de validité du test T”

NB : PAS de test de normalité !!

4.B.1 Test de normalité

En épistémologie : pour Neyman et Pearson :

- Hypothèse nulle : distrubutions normales
- Hypothèse alternative : distributions non normales

Il faudrait calculer la puissance du test pour vérifier si on peut rejeter l’hypothèse nulle !!

Et c’est impossible de calculer la puissance du test de normalité de Shapiro-Wilk

- H0 : $\mathcal{L}(x, \theta_0)$: vraisemblance des données x sous H0
- H1 : $\mathcal{L}(x, \theta_1)$: vraisemblance des données x sous H1
- k_α : valeur seuil dépendant de alpha

Et le calcul de puissance (θ_1) ou $1 - \beta$ est IMPOSSIBLE !!

Donc les tests de normalité soulèvent des problèmes de puissance.

En pratique pour visualiser la normalité : histogramme et Q-Q plot.

Pour Falissard : la VRAIE RIGUEUR, c’est de vérifier la normalité GRAPHIQUEMENT.

4.B.2 Égalité des variances

Dans R : fonction `by()` pour calculer les variances par groupe

```
by(smp$schizophrenie, smp$tbl.bipol, var)
```

```
smp$tbl.bipol: 0
[1] 0.07768546
------------------------------------------------------------
smp$tbl.bipol: 1
[1] 0
```

4.C Test de nullité du coefficient de corrélation

Très robuste !

- Conditions d’application : au moins une distribution normale

4.D Si conditions non valides

- Boostrap : si N > 20 dans chaque groupe
- Distributions très irrégulières : soit transformer les données, soit tests non paramétriques type bootstrap.
- Tests non paramétriques :

- Test de Mann-Whitney : comparaison de deux groupes (quantitative)
- Test de Kruskal-Wallis : comparaison de plusieurs groupes (quantitative)
- Test de Wilcoxon : comparaison de deux mesures appariées (quantitative)
- Test de Friedman : comparaison de plusieurs mesures appariées (quantitative)
- Test exact de Fisher : comparaison de pourcentages (qualitative)

5 Interprétation des résultats et des tests

5.A Fisher :

- échantillon : tiré au sort depuis une population infinie hypothétique
- petit p : probabilité que le résultat observé soit applicable à la population infinie hypothétique !

Exemple :

- On tire 30 personnes parmi celles qui passent devant Bicêtre
- On mesure leur taille
- On calcule la moyenne + intervalle de confiance de la taille dans notre échantillon
- On obtient une moyenne + une intervalle qui permet d'estimer la moyenne de la taille dans une population de CLONES STRICTEMENT IDENTIQUE de la population de l'échantillon !

$\longrightarrow$ La VRAIE population est une population FANTASMÉE !

La population infinie hypothétique n'a pas de raison de ressembler à la population réelle !!

Intervalle de confiance: estimateur de la variabilité d'un paramètre dans une population multipliée de notre échantillon !

> si p = 0.02 : la probabilité que le hasard explique un tel résulat est de 2%

5.B Neyman-Pearson

Surtout pour essais cliniques !

- H0 : hypothèse nulle : P(A) = P(B)
- H1 : hypothèse alternative : P(A) - P(B) > Δ
- p < α : rejet de H0

3 risques estimés *a priori* :

α : risque de première espèce (erreur de type I)

β : risque de deuxième espèce (erreur de type II)

Δ : différence minimale cliniquement importante

6 Conclusion

1. Se poser une question
2. Choisir un design
3. Choisir un test
4. Calculer un petit p
5. Et interpréter le % du p !
6. Facteurs de confusion et biais qui limiteraient la généralisation à la population globale