Devoir Épidémiologie

Thomas Husson, Groupe 52

Table des matières

1 Introduction **3**
1.A Énoncé du devoir . . . 3
1.B Contexte . . . 3
1.C Plan du devoir . . . 3

2 Data-management **4**
2.A Nettoyage et renommage des variables . . . 4
2.B Taux de données manquantes . . . 4
2.C Conversion des types de données . . . 5
2.D Vérification de la cohérence des dates . . . 5

3 Description du jeu de données **5**
3.A Vue d'ensemble du jeu de données . . . 5
3.B Variables catégorielles . . . 6
3.C Variables numériques . . . 12

4 Analyse non ajustée **16**
4.A Résultats . . . 16
4.B Exploration des facteurs de confusion potentiels . . . 18
4.C Les patients ayant eu un cathétérisme cardiaque droit sont-ils comparables aux patients n'en ayant pas eu ? . . . 18

5 Appariement selon score de propension **24**
5.A Quelles variables inclure dans le score de propension ? . . . 24
5.B Calcul du score de propension et appariement . . . 25
5.C Évaluation de l'équilibre des covariables après appariement et de la qualité de l'appariement . . . 26

6 Analyse après appariement **30**
6.A Résultats . . . 30
6.B Interprétation des résultats . . . 33

7 Autre approche : analyse multivariée sur la population totale (non appariée) **34**
7.A Principe . . . 34
7.B Quelles variables inclure dans le modèle de survie multivarié ? . . . 34
7.C Mise en œuvre du modèle de survie multivarié . . . 34
7.D Interprétation des résultats du modèle de régression multivariée . . . 34

8 Conclusion **35**

9 Bibliographie **36**

10 Annexes **37**
10.A Tableau comparatif post-appariement . . . 37
10.B code R . . . 38

! Important

Utilisation de l'IA
Des LLMs ont été utilisés à plusieurs reprises dans ce devoir, pour deux tâches principales :

- En cas de problème d'exécution du code R (pour suggérer correction et amélioration)
- Pour amélioration du rendu depuis un fichier Quarto Markdown vers PDF.

Utilisation de Gemini pour le rendu Quarto et Github Copilot pour le code R.

1 Introduction

1.A Énoncé du devoir

- Étude observationnelle réalisée en unité de soins intensifs
- Question : efficacité de la pose d'une sonde de Swan Ganz (*Right Heart Catheterization*, RHC) sur la mortalité des patients critiques, en tenant compte des facteurs pronostiques et des risques associés à cette procédure invasive.
- Objectif : évaluer l'apport de la procédure de cathétérisme cardiaque droit sur la mortalité, en tenant compte des nombreux facteurs pronostiques.
- Source : Connors et al. (1996) : The effectiveness of RHC in the initial care of critically ill patients. J American Medical Association 276 :889-897.

1.B Contexte

- Cathéter de Swan Ganz : dispositif médical diagnostique et thérapeutique mesurant en temps réel le débit et les pressions sanguines dans les cavités cardiaques droites et l'artère pulmonaire par cathétérisme cardiaque droit (RHC).
- Utilisé en réanimation à partir des années 1970, mais remis en question après réévaluation du rapport bénéfice/risque.
- Études randomisées contrôlées difficiles à réaliser pour des raisons éthiques, car de nombreux praticiens considèrent que ne pas utiliser la sonde de Swan-Ganz pourrait entraîner une perte de chances pour les patients.
- Étude observationnelle conçue par Connors et al. pour aborder la question d'un point de vue épidémiologique, avec une cohorte prospective multicentrique de 5735 patients adultes hospitalisés en réanimation pour une déficience d'organe parmi 9 prédéfinies, dont 2184 ont eu un RHC.
- Données rapportées : survie à J30, durée d'hospitalisation en réanimation et hospitalisation traditionnelle, coût du séjour, intensité des soins reçus.

1.C Plan du devoir

- Data-management : nettoyage du jeu de données, renommage des variables et de leurs catégories, remise à l'échelle le cas échéant, prise en compte des données aberrantes ou manquantes.
- Analyse descriptive univariée de la population, des différentes variables et de leur répartition au sein de la cohorte.
- Analyse bivariée de ces variables au sein de sous-groupes : chez les patients ayant reçu ou non un RHC, ainsi que chez les patients décédés ou non à J30, afin de mettre en évidence une éventuelle différence significative entre les groupes.
- Analyse multivariée pour répondre à la question posée : la réalisation d'un cathétérisme cardiaque droit est-elle bénéfique au patient, toute covariable d'ajustement étant comparable par ailleurs ?
- Pour éviter un biais d'indication et améliorer la comparabilité des patients, un score de propen-

sion à la réalisation d'un cathétérisme cardiaque droit a été conçu par régression logistique multiple, permettant un ajustement sur un grand nombre de variables de confusion potentielles.

— Analyse de survie à J30, comparant les populations ayant reçu ou non le RHC, toute chose étant comparable par ailleurs grâce à l'ajustement sur le score de propension.

— Conclusion : synthèse des résultats, discussion des limites de l'étude, implications cliniques et perspectives de recherche future.

2 Data-management

— Le fichier contient 5735 observations et 63 variables, avec des types de données variés (numériques, caractères, facteurs).

— La première colonne et la dernière sont inutiles pour l'analyse (identifiant et index), et seront supprimées.

— Les variables de date sont au format caractère et doivent être converties en format date pour une manipulation plus facile.

— Les variables de type "Yes"/"No" seront converties en facteurs pour faciliter l'analyse statistique.

— Les colonnes sont renommées pour faciliter leur manipulation et leur compréhension.

2.A Nettoyage et renommage des variables

2.B Taux de données manquantes

Table 1 – Résumé des données manquantes par variable

Variable	Nombre de données manquantes	Pourcentage de données manquantes
adl_score	4296	74.9
urine_output	3028	52.8

— Les variables `adl_score` et `urine_output` sont les deux seules à avoir des données manquantes.

— Pour la variables `adl_score` (correspondant au score ADL), le taux de données manquantes est de 74,9%.

— Pour la variable `urine_output` (correspondant à la diurèse), le taux de données manquantes est de 52,8%.

2.C Conversion des types de données

2.D Vérification de la cohérence des dates

2.D.1 Vérification de la cohérence entre date de décès et date des dernières nouvelles

— Il existe une colonne codant pour la date de décès et une codant pour la date des dernières nouvelles.

— Pour les patients décédés, on vérifie que la date de décès correspond à la date des dernières nouvelles

— Il existe 2154 cas où les dates des dernières nouvelles sont incohérentes (soit postérieure à la date de décès, soit antérieure) : pour ces patients, on propose de corriger la date des dernières nouvelles en la remplaçant par la date de décès.

— Après correction il existe 0 cas incohérents, ce qui correspond à une correction réussie de tous les cas de dates incohérentes entre date de décès et date des dernières nouvelles.

2.D.2 Vérification de la cohérence entre date de sortie d'hospitalisation et date des dernières nouvelles

— On vérifie que la date de sortie d'hospitalisation n'est pas postérieure à la date des dernières nouvelles, ce qui serait incohérent.

— 1 patient a une date de sortie d'hospitalisation inconnue

— Une vérification rapide montre qu'il est décédé 394 jours après son admission. On ne peut pas affirmer que le patient est sorti entre temps de son hospitalisation.

3 Description du jeu de données

3.A Vue d'ensemble du jeu de données

— Nombre d'observations et de variables

Table 2 – Nombre d'observations et de variables

Nom	Nombre d'observations	Nombre de variables
df	5735	78

— Types de variables (catégorielles, numériques, dates)

Table 3 – Types de variables

Type	Nombre
factor	33
numeric	24

Type	Nombre
character	17
Date	4

3.B Variables catégorielles

— Nom des variables catégorielles

Table 4 – Variables catégorielles

Variable	Description
primary_disease_category	Diagnostic principal
secondary_disease_category	Comorbidité principale
cancer	Cancer (No, Yes, Metastatic)
death_180d	Décès à 180 jours (Yes/No)
comorbidity_cardiovascular	Antécédent : cardiovasculaire
comorbidity_congestive_heart	Antécédent : insuffisance cardiaque
comorbidity_dementia	Antécédent : démence
comorbidity_psych	Antécédent : psychiatrique
comorbidity_chronic_pulmonary	Antécédent : respiratoire chronique
comorbidity_renal	Antécédent : rénal
comorbidity_liver	Antécédent : hépatique
comorbidity_upper_gi_bleeding	Antécédent : hémorragie digestive haute
comorbidity_malignancy	Antécédent : cancer
comorbidity_immunosuppression	Antécédent : immunodépression
comorbidity_transfer	Transfert (> 24h)
comorbidity_myocardial_infarction	Antécédent : infarctus du myocarde
sex	Sexe
death_30d	Décès à 30 jours
rhc	Cathétérisme cardiaque droit (RHC)
dnr_status	Statut de non-réanimation (DNR)
insurance_class	Classe d'assurance
diagnosis_respiratory	Diagnostic : respiratoire
diagnosis_cardiovascular	Diagnostic : cardiovasculaire
diagnosis_neurological	Diagnostic : neurologique
diagnosis_gastrointestinal	Diagnostic : gastro-intestinal
diagnosis_renal	Diagnostic : rénal
diagnosis_metabolic	Diagnostic : métabolique
diagnosis_hematologic	Diagnostic : hématologique
diagnosis_sepsis	Diagnostic : sepsis
diagnosis_trauma	Diagnostic : traumatique
diagnosis_orthopedic	Diagnostic : orthopédique
race	Origine / race (selon codage de la base)
income	Revenu (selon codage de la base)

— On peut séparer les variables catégorielles en plusieurs "sous-catégories" selon leur thème :

comorbidités, diagnostics, variables sociodémographiques, etc.

3.B.1 Diagnostic principal et comorbidité principale

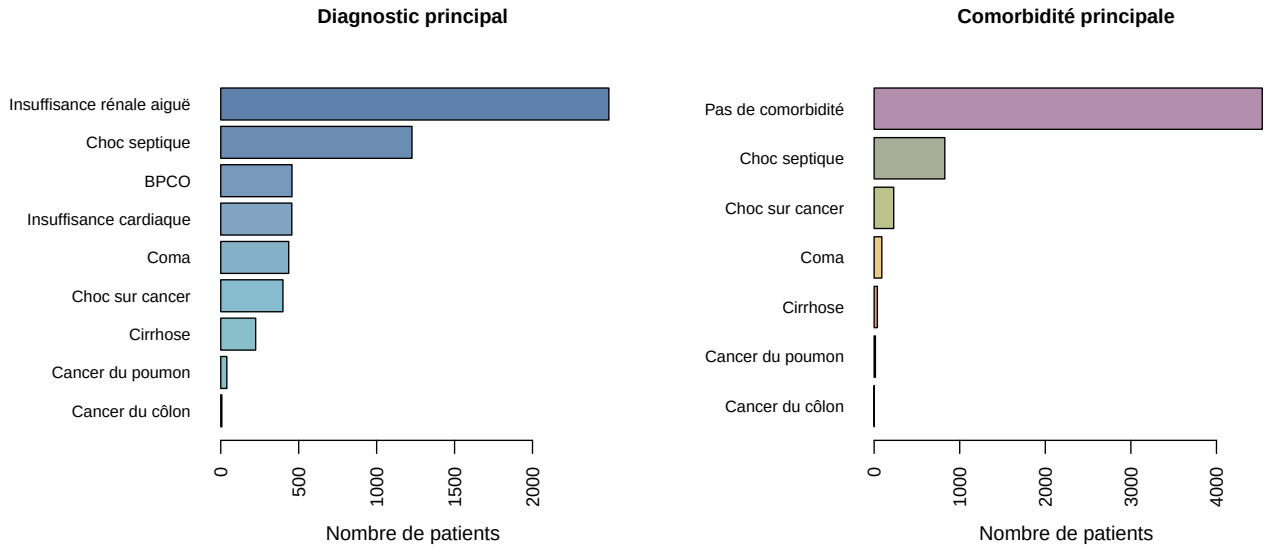

FIGURE 1 – Distribution des modalités (diagnostic principal et comorbidité principale)

3.B.2 Diagnostic et comorbidités (variables "Yes"/"No")

— Les variables de diagnostic et de comorbidités sont codées "Yes"/"No". On peut visualiser la distribution des modalités pour chacune de ces variables à l'aide de diagrammes en batons (barplots).

3.B.2.1 Diagnostics

— Il existe 10 variables de diagnostic codées "Yes"/"No" : respiratoire, cardiovasculaire, neurologique, gastro-intestinal, rénal, métabolique, hématologique, sepsis, trauma et orthopédique.

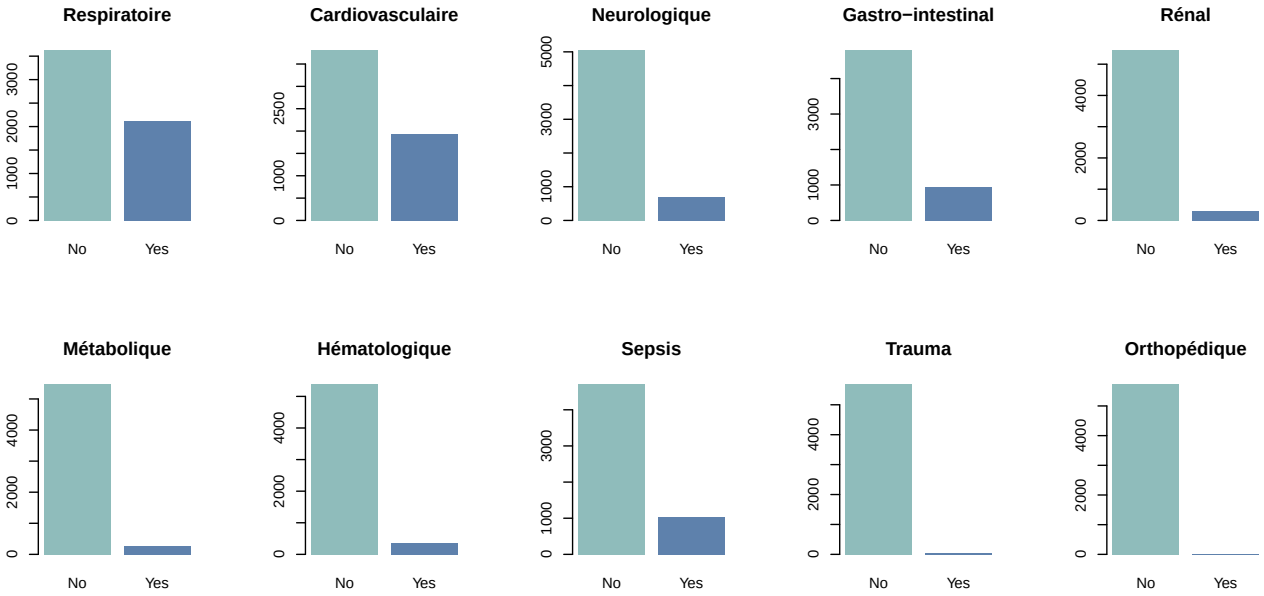

FIGURE 2 – Distribution des modalités (diagnostics)

3.B.2.2 Comorbidités

— Il existe 12 variables de comorbidités codées “Yes”/“No” : cardiovasculaire, insuffisance cardiaque, démence, psychiatrique, respiratoire chronique, rénal, hépatique, hémorragie digestive haute, cancer, immunodépression, transfert (> 24h) et infarctus du myocarde.

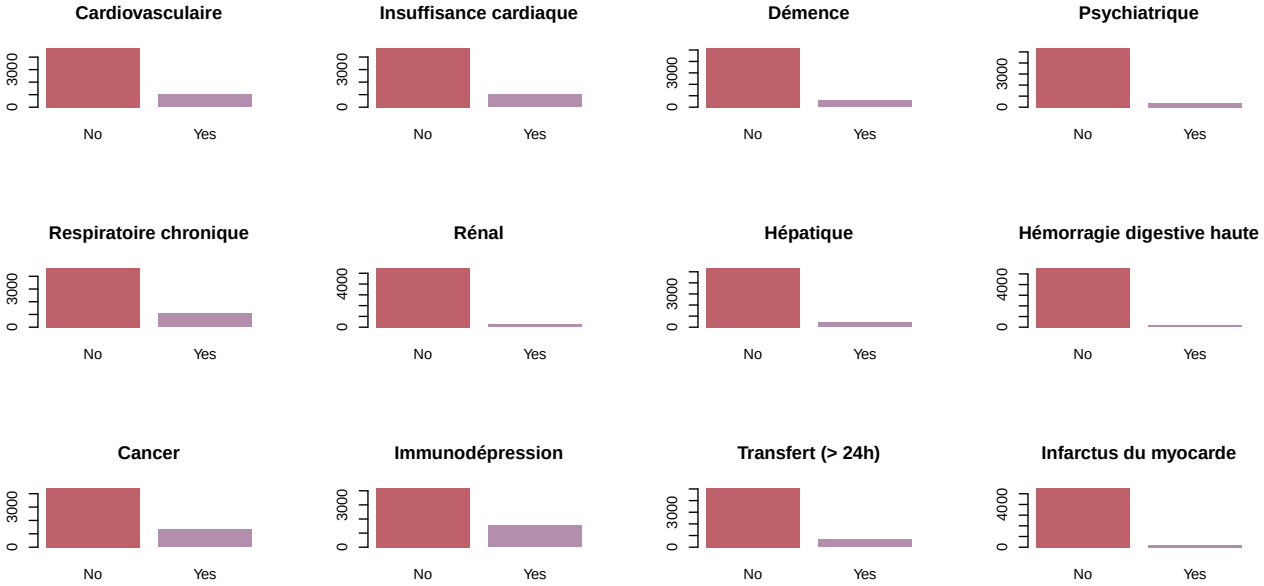

FIGURE 3 – Distribution des modalités (comorbidités)

3.B.2.3 En un seul graphique

— Permet de mieux visualiser car même échelle pour tous, mais moins lisible car plus petit (surtout pour les moins fréquents)

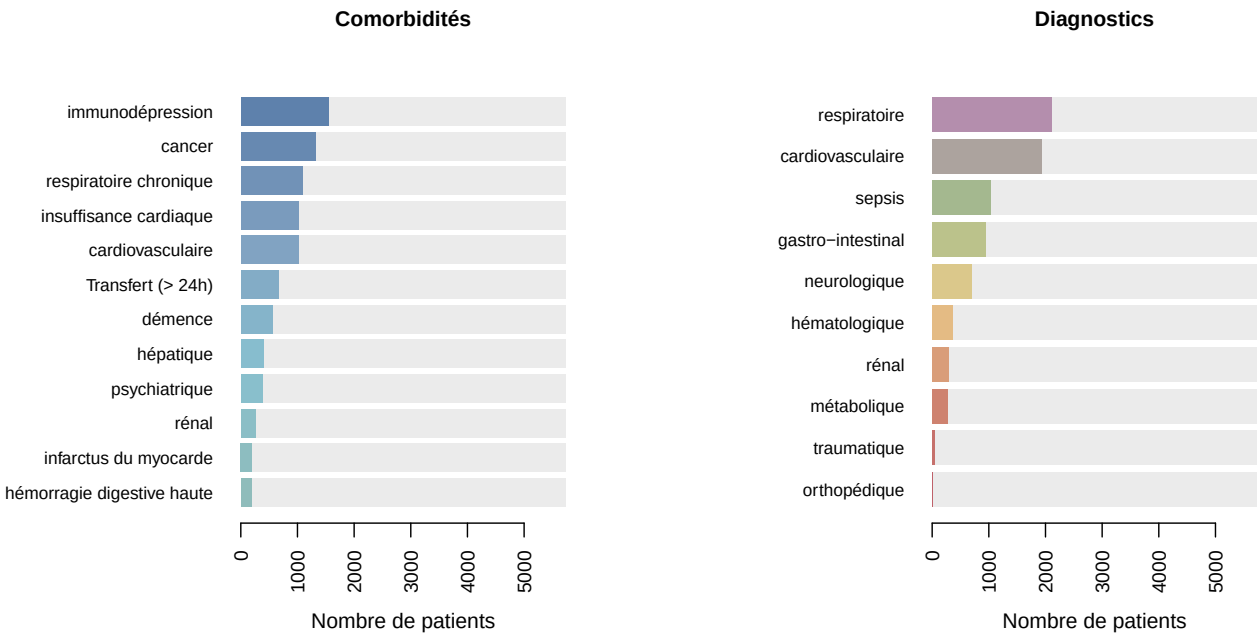

FIGURE 4 – Distribution des modalités (diagnostics et comorbidités)

3.B.3 Variables sociodémographiques

— Il existe 5 variables sociodémographiques : sexe, statut non-réanimatoire, classe d'assurance, origine, revenu

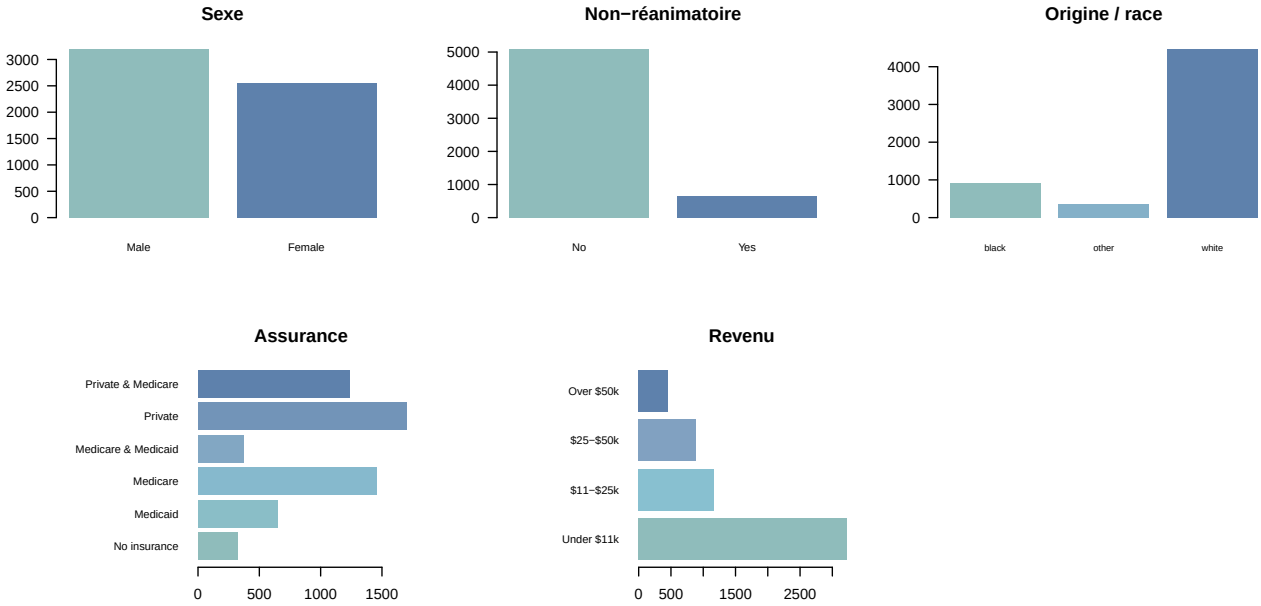

FIGURE 5 – Distribution des modalités (variables sociodémographiques)

3.B.4 Cancer

— La variable "cancer" était initialement codée en 3 modalités : "No", "Yes" et "Metastatic".

— Du fait que les patients ayant la variable codée soit “Yes”, soit “Metastatic”, on en déduit que “Yes” correspond à un cancer localisé, tandis que “Metastatic” correspond à un cancer métastatique.

— Une variable binaire “cancer_YN” a été créée à partir de la variable “cancer”, codée “Yes” si le patient a un cancer (localisé ou métastatique) et “No” sinon.

Table 5 – Pourcentage de patients avec cancer et répartition (Localisé vs Métastatique)

Variable	Pourcentage	Effectifs
Cancer (Yes/No)	23.6%	1356/5735
Cancer localisé	71.7%	972/1356
Cancer métastatique	28.3%	384/1356

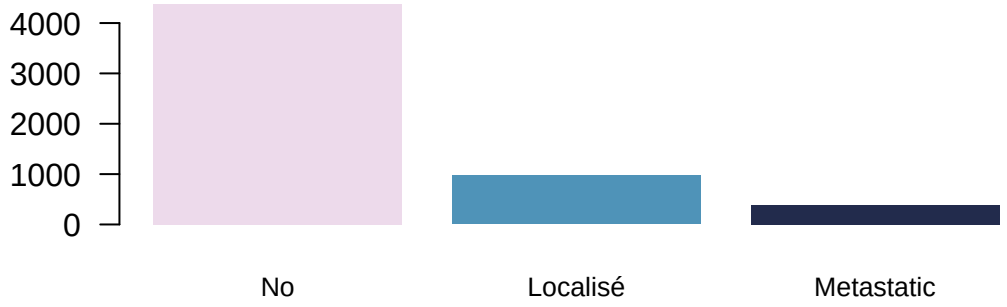

Figure 6 – Distribution des modalités (cancer)

3.B.5 Variables liées au décès

— À 30 jours : 1918 patients sont décédés, soit 33.4% de la cohorte.

— À 180 jours : 3722 patients sont décédés, soit 64.9% de la cohorte.

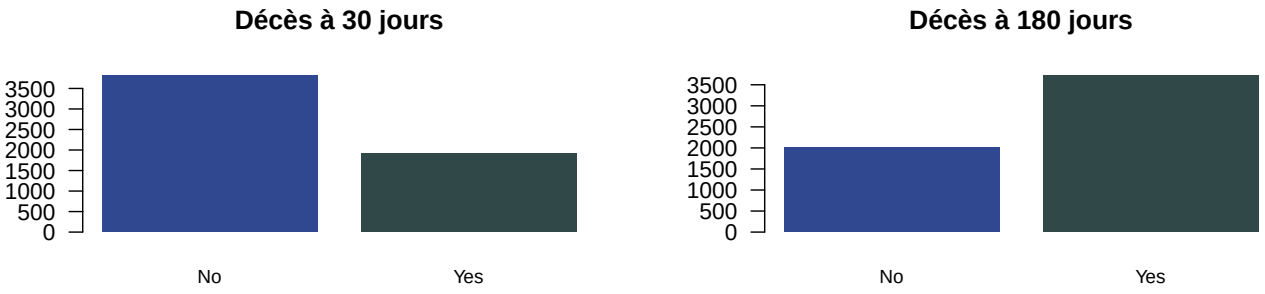

Figure 7 – Distribution des modalités (décès à 180 jours et à 30 jours)

Table 6 – Pourcentage de décès à 30 jours et à 180 jours

Variable	Pourcentage	Effectifs
Décès à 30 jours	33.4%	1918/5735
Décès à 180 jours	64.9%	3722/5735

3.B.6 Cathéterisme cardiaque droit (RHC)

— 2184 patients ont eu un cathétérisme cardiaque droit (RHC), soit 38.1% de la cohorte.

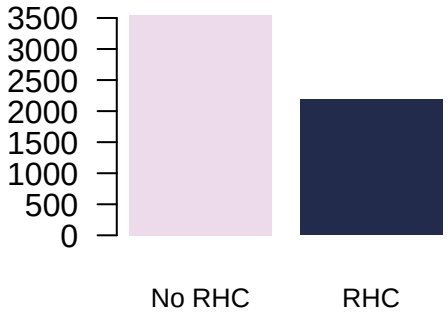

Figure 8 – Distribution des modalités (cathétérisme cardiaque droit)

Table 7 – Pourcentage de patients ayant eu un cathétérisme cardiaque droit (RHC)

Variable	Pourcentage	Effectifs
Cathéterisme cardiaque droit (RHC)	38.1%	2184/5735

3.C Variables numériques

— Nombre de variables numériques : 24

3.C.1 Tableau récapitulatif des variables numériques

Table 8 – Variables numériques

Variables	Moyenne	SD	Médiane	Q1	Q3	Min	Max
Âge (années)	61.38	16.68	64.05	50.15	73.93	18.04	101.85
Niveau d'études (années)	11.68	3.15	12.00	10.00	13.00	0.00	30.00
Probabilité de survie prédite	0.59	0.20	0.63	0.47	0.74	0.00	0.96
Score DASI	20.50	5.32	19.75	16.06	23.43	11.00	33.00
Score APACHE	54.67	19.96	54.00	41.00	67.00	3.00	147.00
Score de Glasgow	21.00	30.27	0.00	0.00	41.00	0.00	100.00
Pression artérielle moyenne	78.52	38.05	63.00	50.00	115.00	0.00	259.00
Leucocytes (x10^9/L)	15.65	11.87	14.10	8.40	20.05	0.00	192.00
Fréquence cardiaque (bpm)	115.18	41.24	124.00	97.00	141.00	0.00	250.00
Fréquence respiratoire (rpm)	28.09	14.08	30.00	14.00	38.00	0.00	100.00
Température (°C)	37.62	1.77	38.09	36.09	39.00	27.00	43.00
Rapport PaO2/FiO2	222.27	114.95	202.50	133.31	316.62	11.60	937.50
Albumine (g/L)	3.09	0.78	3.50	2.60	3.50	0.30	29.00
Hématocrite (%)	31.87	8.36	30.00	26.10	36.30	2.00	66.19
Bilirubine (mg/L)	2.27	4.80	1.01	0.80	1.40	0.10	58.20
Créatinine (mg/L)	2.13	2.05	1.50	1.00	2.40	0.10	25.10
Sodium (mmol/L)	136.77	7.66	136.00	132.00	142.00	101.00	178.00
Potassium (mmol/L)	4.07	1.03	3.80	3.40	4.60	1.10	11.90
PaCO2	38.75	13.18	37.00	31.00	42.00	1.00	156.00
pH	7.39	0.11	7.40	7.34	7.46	6.58	7.77
Poids (kg)	67.83	29.06	70.00	56.30	83.70	0.00	244.00
Score ADL	1.18	1.82	0.00	0.00	2.00	0.00	7.00
Diurèse	2192.45	1525.14	1927.00	1110.00	2955.00	0.00	9000.00

— On constate quelques valeurs aberrantes dans les variables numériques :

  — Pression artérielle moyenne minimale à 0mmHg.

  — Leucocytose minimale à 0 G/L.

  — Fréquence cardiaque minimale à 0 bpm.

  — Fréquence respiratoire minimale à 0 resp/min.

  — Poids minimal à 0 kg.

3.C.2 Gestion des valeurs aberrantes dans les variables numériques

Table 9 – Valeurs aberrantes dans les variables numériques

Variable	Valeur.aberrante	Pourcentage.de.valeurs.0
Pression artérielle moyenne	80	1.39
Leucocytose	4	0.07
Fréquence cardiaque	159	2.77
Fréquence respiratoire	136	2.37
Poids	515	8.98

— Le taux de valeurs “0” est relativement faible pour chacune de ces variables, ce qui suggère que ces valeurs pourraient être des erreurs de saisie ou des données manquantes codées à tort comme “0”.

— Au maximum, la variable “Poids” contient 8.98% de valeurs “0”, ce qui est relativement faible.

— On propose d’imputer toutes ces valeurs manquantes par la médiane de chaque variable, ce qui est une méthode simple et robuste pour gérer les valeurs aberrantes et les données manquantes.

3.C.3 Tableau récapitulatif des variables numériques après imputation

Table 10 – Variables numériques après imputation des valeurs aberrantes

Variables	Moyenne	SD	Médiane	Q1	Q3	Min	Max
mean_blood_pressure	79.40	36.93	63.0	50.0	115.00	10.00	259
wbc	15.65	11.86	14.1	8.4	20.05	0.05	192
heart_rate	118.62	36.38	124.0	105.0	141.00	8.00	250
respiratory_rate	28.80	13.38	30.0	18.0	38.00	2.00	100
weight	74.31	19.77	72.2	61.7	83.70	19.50	244

Table 11 – Variables numériques après imputation des valeurs aberrantes

Variables	Moyenne	SD	Médiane	Q1	Q3	Min	Max
mean_blood_pressure	79.40	36.93	63.0	50.0	115.00	10.00	259
wbc	15.65	11.86	14.1	8.4	20.05	0.05	192
heart_rate	118.62	36.38	124.0	105.0	141.00	8.00	250
respiratory_rate	28.80	13.38	30.0	18.0	38.00	2.00	100
weight	74.31	19.77	72.2	61.7	83.70	19.50	244

3.C.4 Histogramme et courbes de densité pour chacune des variables numériques

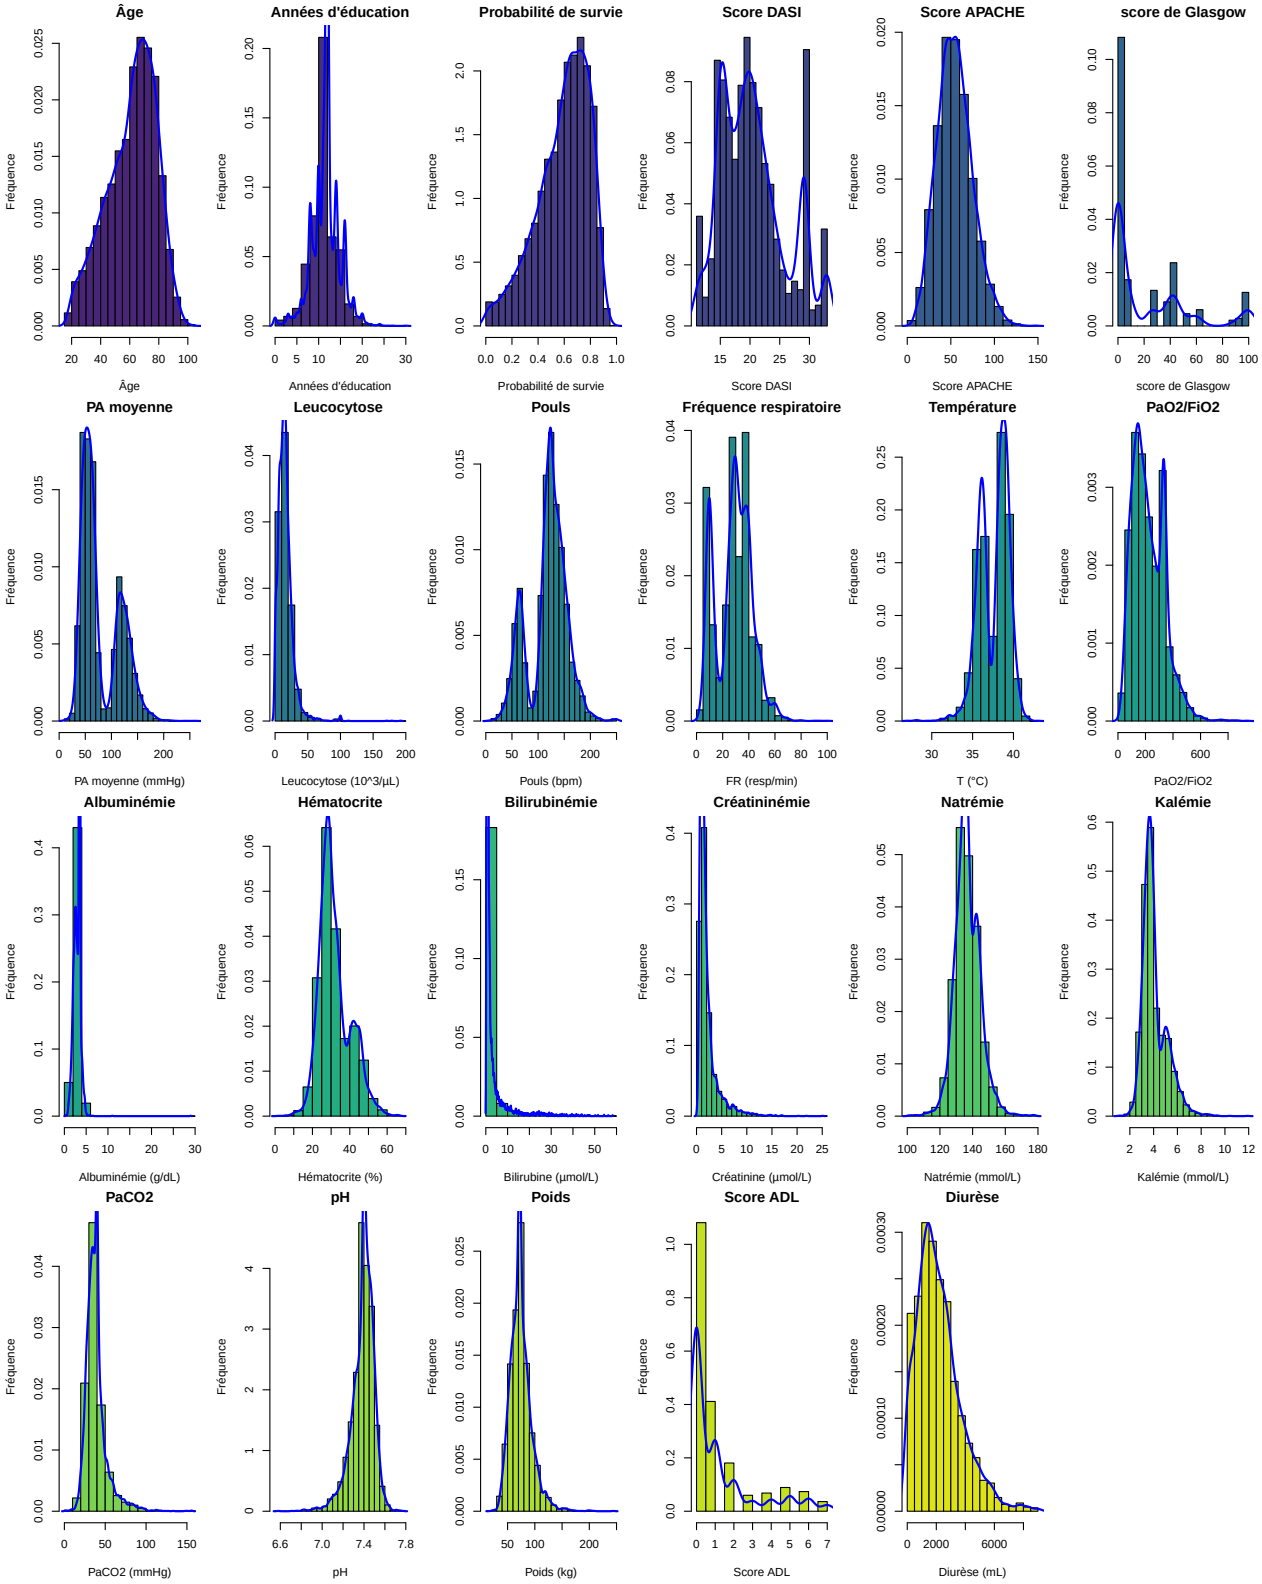

FIGURE 9 – Distribution des variables numériques (histogrammes et courbes de densité)

3.C.5 Normalité des variables

— Certaines variables numériques semblent suivre une distribution approximativement normale : c'est le cas de l'âge (même prédominance des âges jeunes donc asymétrie vers les âges plus élevés).

— A titre complémentaire, on peut réaliser un QQ-plot pour l'âge par exemple, qui visualise la distribution des données par rapport à une distribution normale théorique.

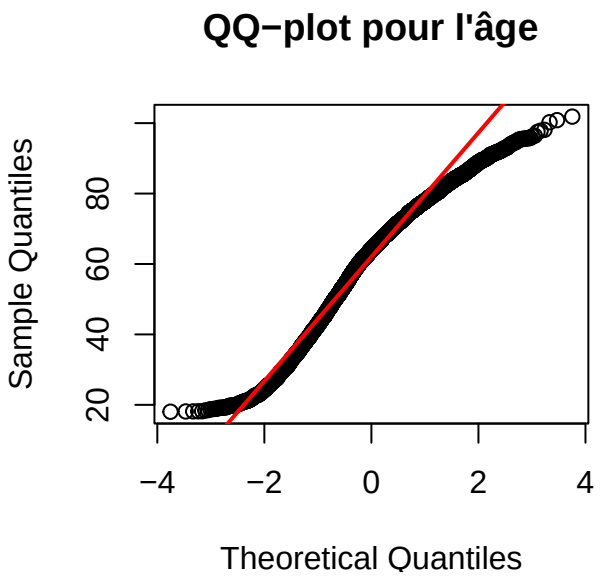

FIGURE 10 – QQ-plot pour l'âge

4 Analyse non ajustée

4.A Résultats

- L'objectif de l'étude est d'évaluer le cathétérisme cardiaque droit (RHC) sur plusieurs critères : temps de survie, durée de séjour à l'hôpital et en réanimation, coûts hospitaliers et intensité des soins.
- On ne dispose pas dans le jeu de données d'informations sur les coûts hospitaliers et l'intensité des soins, donc on se concentre sur les deux premiers critères : temps de survie et durée de séjour à l'hôpital et en réanimation.
- Il s'agit d'une analyse non ajustée, c'est à dire sans contrôle pour les facteurs de confusion potentiels.

4.A.1 En utilisant des critères binaires (décès à 30 jours et à 180 jours)

Table 12 – Comparaison des décès à 30 jours et à 180 jours entre les groupes RHC vs non-RHC

Variable	**No RHC** N = 3,551[1]	**RHC** N = 2,184[1]	**p-value**[2]
Décès à 30 jours	1,088 (31%)	830 (38%)	<0.001
Décès à 180 jours	2,236 (63%)	1,486 (68%)	<0.001

[1] n (%)
[2] Pearson's Chi-squared test

Table 13 – Odds Ratio (OR) pour le décès à 30 jours et à 180 jours

Critère	OR	IC 95%
Décès à 30 jours	1.39	(1.24, 1.55)
Décès à 180 jours	1.25	(1.12, 1.4)

- Il y a significativement plus de décès à 30 jours et à 180 jours dans le groupe RHC que dans le groupe non-RHC ($p < 0.001$ pour les deux critères).
- Les OR sont de 1.39 pour le décès à 30 jours et de 1.25 pour le décès à 180 jours, indiquant une association positive entre le RHC et le risque de décès à ces deux critères.

4.A.2 En utilisant des critères de temps de survie (temps jusqu'au décès ou censure)

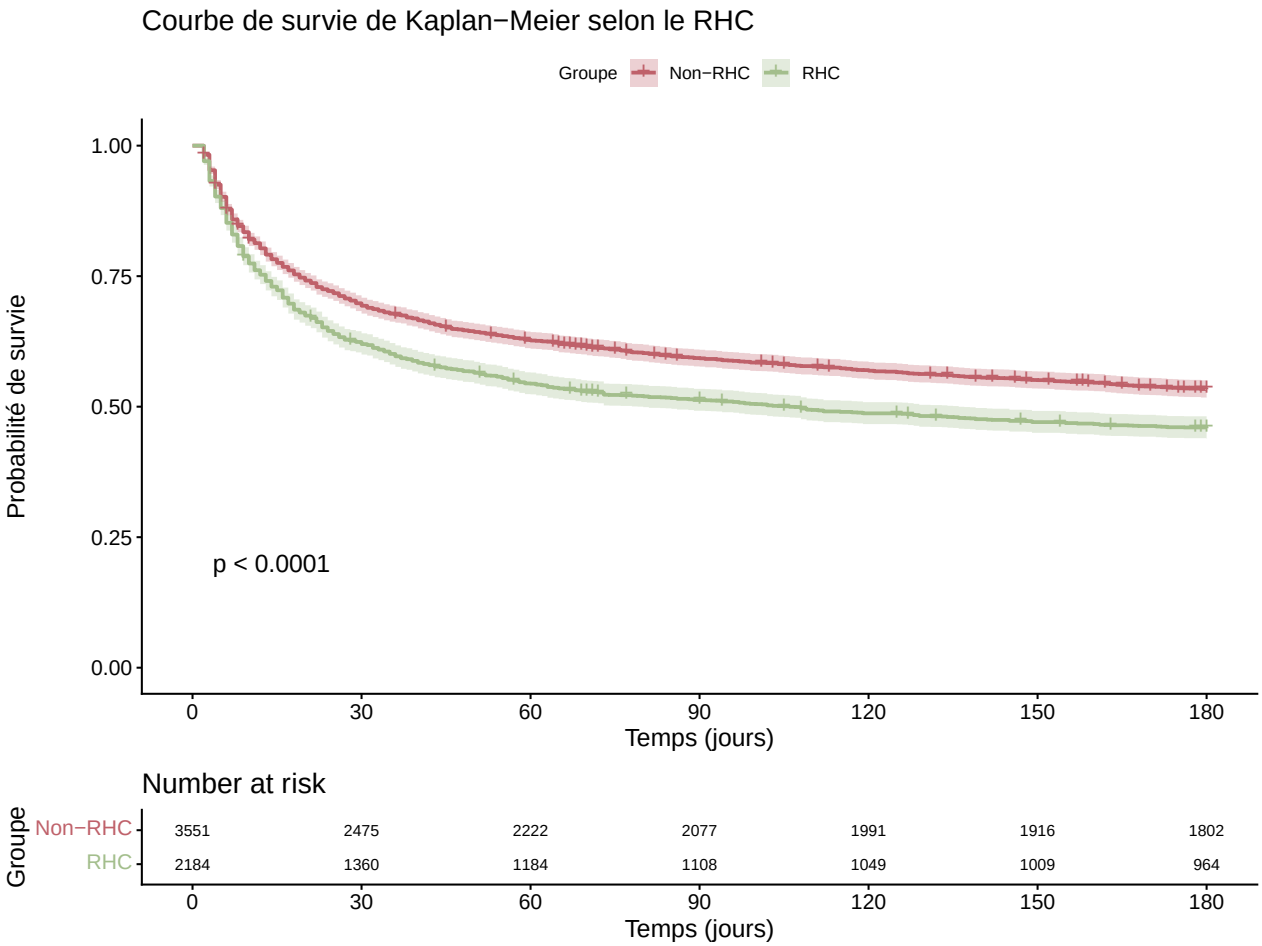

— Le test du log rank indique une différence significative entre les courbes de survie des groupes RHC et non-RHC ($p < 0.001$), suggérant une différence entre les deux courbes de survie.

— L'hypothèse de proportionnalité des risques semble être vérifiée, car les courbes de survie ne se croisent pas et restent parallèles au fil du temps

! Interprétation dans ce contexte

— Ces tests supposent la comparabilité des groupes !

— On ne sait pas si le décès est survenu à cause du cathétérisme cardiaque ou si les patients ayant eu un cathétérisme étaient plus graves au départ

— En l'absence de randomisation, il est très probable que les patients ayant eu un RHC étaient plus sévères au départ, ce qui pourrait expliquer la plus grande mortalité observée dans ce groupe.

— Il est donc essentiel de réaliser une analyse ajustée pour contrôler les facteurs de confusion potentiels avant de tirer des conclusions sur l'effet du RHC sur la mortalité.

4.B Exploration des facteurs de confusion potentiels

- On a donc observé que :
  - Les patients ayant eu un cathétérisme cardiaque droit (RHC) ont une mortalité plus élevée à 30 jours et à 180 jours que les patients n'ayant pas eu de RHC.
  - Les courbes de survie de Kaplan-Meier sont différentes, selon que les patients ont eu ou non un RHC.
  - Il s'agit probablement d'une association confondue par la sévérité initiale des patients, car les patients ayant eu un RHC étaient probablement plus sévères au départ.
- Il faut donc réaliser une analyse ajustée pour contrôler les facteurs de confusion potentiels et améliorer la comparabilité des groupes RHC vs non-RHC.
- Il est probable que les patients ayant eu un RHC étaient plus sévères au départ, ce qui pourrait expliquer la plus grande mortalité observée dans ce groupe
- Il est donc essentiel d'explorer les caractéristiques basales des patients dans les groupes RHC vs non-RHC pour identifier les facteurs de confusion potentiels et évaluer la comparabilité des groupes avant de réaliser une analyse ajustée.

4.C Les patients ayant eu un cathétérisme cardiaque droit sont-ils comparables aux patients n'en ayant pas eu ?

- Il est important d'évaluer si les patients ayant eu un RHC sont différents des patients n'ayant pas eu de RHC en termes de caractéristiques basales, car cela peut indiquer la présence d'un biais de confusion.
- Cela peut inclure des facteurs tels que l'âge, le sexe, la comorbidité, et la sévérité de la maladie au moment de l'admission.
- Pour évaluer :
  - Une analyse univariée avec test pour chaque variable (test de chi2 pour les variables catégorielles, test de t pour les variables numériques) peut être réalisée pour comparer les caractéristiques basales entre les groupes RHC et non-RHC, mais ça va donner beaucoup de p-values à interpréter et il y a un risque de surinterprétation des résultats.
  - On peut réaliser un "love plot" pour visualiser les différences moyennes standardisées (qui correspondent à la différence de moyenne entre les groupes RHC et non-RHC, divisée par l'écart-type) pour chaque variable, avant et après ajustement (par exemple, après appariement). Cela permet de visualiser l'équilibre des covariables entre les groupes.

4.C.1 Tests comparatifs des caractéristiques basales entre les groupes RHC vs non-RHC

Table 14 – Comparaison des caractéristiques basales entre les groupes RHC vs non-RHC

Variable	No RHC N = 3,551	RHC N = 2,184	p-value
Démographie / socio-économique			
Âge	62 (17)	61 (16)	0.022
Sexe			<0.001
Male	1,914 (54%)	1,278 (59%)	
Female	1,637 (46%)	906 (41%)	
Ethnie			0.4
black	585 (16%)	335 (15%)	
other	213 (6.0%)	142 (6.5%)	
white	2,753 (78%)	1,707 (78%)	
Années d'éducation	11.6 (3.1)	11.9 (3.2)	<0.001
Revenu			<0.001
Under $11k	2,081 (59%)	1,145 (52%)	
$11-$25k	713 (20%)	452 (21%)	
$25-$50k	500 (14%)	393 (18%)	
Over $50k	257 (7.2%)	194 (8.9%)	
Classe d'assurance			<0.001
No insurance	186 (5.2%)	136 (6.2%)	
Medicaid	454 (13%)	193 (8.8%)	
Medicare	947 (27%)	511 (23%)	
Medicare & Medicaid	251 (7.1%)	123 (5.6%)	
Private	967 (27%)	731 (33%)	
Private & Medicare	746 (21%)	490 (22%)	
Statut fonctionnel / scores			
Score ADL	1.24 (1.86)	1.02 (1.69)	0.027
Score DASI	20.4 (5.5)	20.7 (5.0)	0.020
Score Coma	22 (31)	19 (28)	<0.001
Score APACHE	51 (19)	61 (20)	<0.001
Statut DNR	499 (14%)	155 (7.1%)	<0.001
Comorbidités			
Cardiopathie	567 (16%)	446 (20%)	<0.001
Insuffisance cardiaque congestive	596 (17%)	425 (19%)	0.010
Infarctus du myocarde	105 (3.0%)	95 (4.3%)	0.005
Maladie pulmonaire chronique	774 (22%)	315 (14%)	<0.001
Insuffisance rénale	149 (4.2%)	106 (4.9%)	0.2
Insuffisance hépatique	265 (7.5%)	136 (6.2%)	0.075
Saignement GI supérieur	131 (3.7%)	54 (2.5%)	0.011
Démence	413 (12%)	151 (6.9%)	<0.001
Psychologique	286 (8.1%)	100 (4.6%)	<0.001
Malignité	872 (25%)	444 (20%)	<0.001
Immunosuppression	907 (26%)	636 (29%)	0.003
Transfert	335 (9.4%)	327 (15%)	<0.001
Diagnostic principal (CAT1)			
BPCO	399 (11%)	58 (2.7%)	<0.001
Choc septique	527 (15%)	700 (32%)	<0.001
Choc sur cancer	241 (6.8%)	158 (7.2%)	0.5
Insuffisance rénale aiguë	1,581 (45%)	909 (42%)	0.031
Insuffisance cardiaque	247 (7.0%)	209 (9.6%)	<0.001
Coma	341 (9.6%)	95 (4.3%)	<0.001
Cirrhose	175 (4.9%)	49 (2.2%)	<0.001
Cancer du poumon	34 (1.0%)	5 (0.2%)	0.001
Cancer du colon	6 (0.2%)	1 (<0.1%)	0.3
Comorbidité principale (CAT2)			
Choc septique	406 (11%)	420 (19%)	<0.001
Choc sur cancer	171 (4.8%)	58 (2.7%)	<0.001

(continued)

Variable	No RHC N = 3,551	RHC N = 2,184	p-value
Coma	70 (2.0%)	20 (0.9%)	0.002
Cirrhose	27 (0.8%)	11 (0.5%)	0.2
Cancer du poumon	13 (0.4%)	2 (<0.1%)	0.048
Cancer du colon	1 (<0.1%)	1 (<0.1%)	>0.9
secondary_binaire_pas_de_comorbidite	2,863 (81%)	1,672 (77%)	<0.001
Diagnostics			
Diagnostic respiratoire	1,481 (42%)	632 (29%)	<0.001
Diagnostic cardiovasculaire	1,007 (28%)	924 (42%)	<0.001
Diagnostic neurologique	575 (16%)	118 (5.4%)	<0.001
Diagnostic gastro-intestinal	522 (15%)	420 (19%)	<0.001
Diagnostic rénal	147 (4.1%)	148 (6.8%)	<0.001
Diagnostic métabolique	172 (4.8%)	93 (4.3%)	0.3
Diagnostic hématologique	239 (6.7%)	115 (5.3%)	0.025
Diagnostic sepsis	515 (15%)	516 (24%)	<0.001
Diagnostic traumatique	18 (0.5%)	34 (1.6%)	<0.001
Diagnostic orthopédique	3 (<0.1%)	4 (0.2%)	0.4
Cancer			
Cancer (Oui/Non)	899 (25%)	457 (21%)	<0.001
Type de cancer			<0.001
No	2,652 (75%)	1,727 (79%)	
Localisé	638 (18%)	334 (15%)	
Metastatic	261 (7.4%)	123 (5.6%)	
Paramètres cliniques			
Poids	72 (20)	77 (20)	<0.001
Pression artérielle moyenne	85 (38)	70 (33)	<0.001
Fréquence cardiaque	116 (37)	123 (35)	<0.001
Fréquence respiratoire	30 (13)	27 (14)	<0.001
Température	37.63 (1.74)	37.59 (1.83)	0.4
Ratio Pa/FI	241 (117)	192 (106)	<0.001
Diurèse	2,199 (1,445)	2,183 (1,635)	0.8
Biologie			
Globules blancs	15 (11)	16 (13)	0.003
Albumine	3.16 (0.67)	2.98 (0.93)	<0.001
Hématocrite	33 (9)	31 (7)	<0.001
Bilirubine	2.00 (4.43)	2.71 (5.33)	<0.001
Créatinine	1.92 (2.03)	2.47 (2.05)	<0.001
Sodium	137 (8)	136 (8)	<0.001
Potassium	4.08 (1.04)	4.05 (1.01)	0.3
PaCO2	40 (14)	37 (11)	<0.001
pH	7.39 (0.11)	7.38 (0.11)	<0.001

[1] Mean (SD) ; n (%)

[2] Welch Two Sample t-test ; Pearson's Chi-squared test ; Fisher's exact test

— Globalement, quasiment toutes les variables sont significativement différentes entre les groupes RHC et non-RHC, ce qui suggère que les patients ayant eu un RHC sont différents des patients n'ayant pas eu de RHC en termes de caractéristiques basales.

4.C.2 Visualisation des différences moyennes standardisées entre les groupes RHC et non-RHC (Love plot)

— On peut aussi visualiser les différences moyennes standardisées pour chaque variable entre les groupes RHC et non-RHC, par exemple à l'aide d'un "love plot", pour mieux visualiser l'équilibre des covariables entre les groupes.

— Les différences moyennes standardisées correspondent à la différence de moyenne entre les groupes RHC et non-RHC, divisée par l'écart-type. Une valeur proche de 0 indique une bonne balance entre les groupes pour cette variable, tandis qu'une valeur éloignée de 0 indique une différence importante entre les groupes pour cette variable.

— Un seuil de 0.1 est souvent utilisé pour indiquer une différence importante entre les groupes : si la différence moyenne standardisée est supérieure à 0.1 en valeur absolue, cela suggère une différence importante entre les groupes pour cette variable.

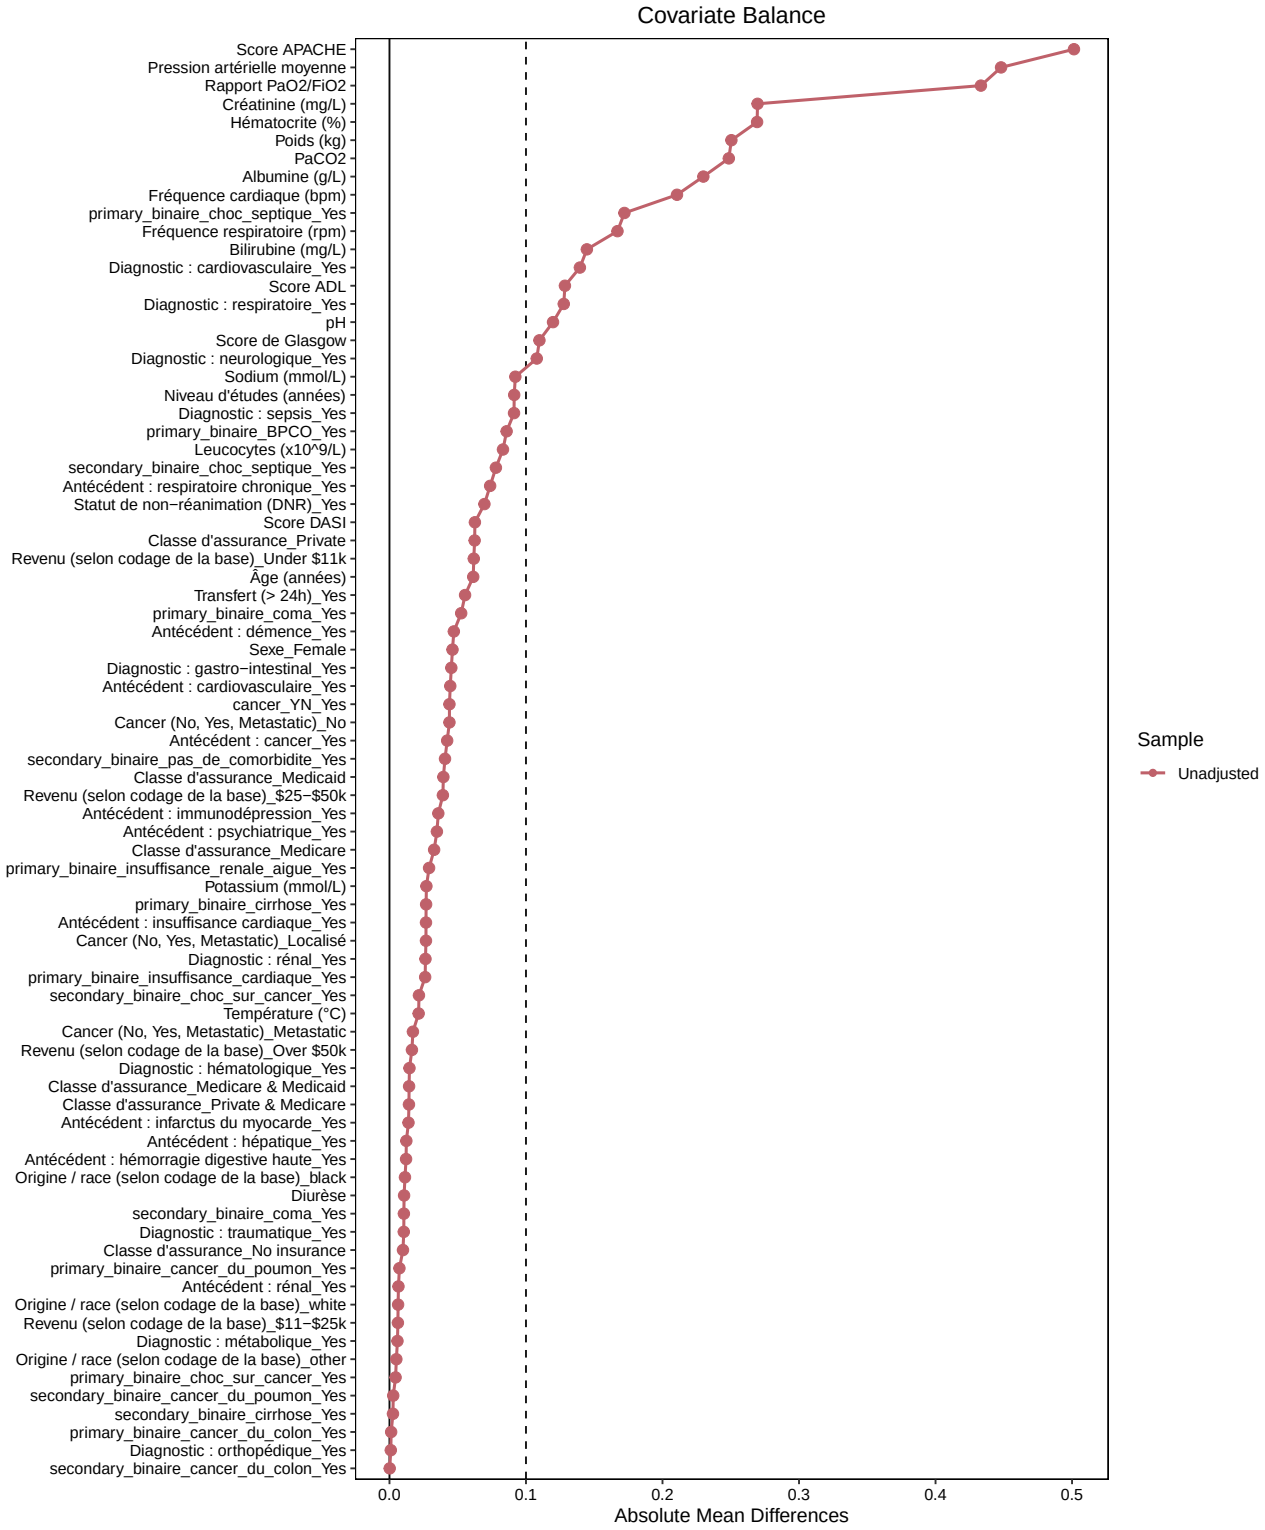

FIGURE 11 – Love plot visualisant les différences moyennes standardisées pour les variables basales

Variable	SMD
adl_score	0.129
glasgow_score	0.110
apache_score	0.501
primary_binaire_choc_septique_Yes	0.172
diagnosis_respiratory_Yes	0.128
diagnosis_cardiovascular_Yes	0.139
diagnosis_neurological_Yes	0.108
weight	0.250
mean_blood_pressure	0.448
heart_rate	0.211
respiratory_rate	0.167
pa_fi_ratio	0.433
albumin	0.230
hematocrit	0.269
bilirubin	0.145
creatinine	0.270
paco2	0.249
ph	0.120

— Les variables ayant une différence moyenne standardisée supérieure à 0.1 en valeur absolue sont le score ADL, le score de Glasgow, le score APACHE, les diagnostics principaux et associés, le poids, la pression artérielle moyenne, la fréquence cardiaque, la fréquence respiratoire, le ratio Pa/FI, l'albumine, l'hématocrite, la bilirubine, la créatinine, la PaCO2 et le pH.

5 Appariement selon score de propension

- Pour assurer la comparabilité initiale des patients, on apparie les patients selon un score de propension calculé à partir de variables "pré-traitement".
- L'objectif est de créer 2 groupes de patients qui auraient des probabilités similaires de recevoir le traitement, afin de réduire les biais de sélection.
- L'identification des variables à inclure est cruciale : il s'agit d'inclure les variables qui influencent le choix du traitement ou non.
- Pour l'identification des variables à inclure, on peut :
  - S'appuyer sur la littérature pour identifier les facteurs connus qui influencent le choix du traitement.
  - Consulter des experts cliniques pour obtenir des insights sur les variables pertinentes.
  - Utiliser des méthodes statistiques pour identifier les variables associées à la fois au traitement et à l'issue.
- Dans notre cas, on a vu que quasiment toutes les variables basales étaient significativement différentes entre les groupes RHC et non-RHC, ce qui suggère que les patients ayant eu un RHC sont différents des patients n'ayant pas eu de RHC en termes de caractéristiques basales.

5.A Quelles variables inclure dans le score de propension ?

5.A.1 Choix des auteurs de l'article original publié

- Dans l'article original publié, les auteurs ont basé leur choix sur une discussion entre 7 experts en soins critiques, qui ont identifié les variables qu'ils considéraient comme étant liées à la décision de réaliser un RHC. Les variables sélectionnées sont :
  - Démographiques : âge (`df$age`), sexe (`df$sex`), race (`df$race`), années d'éducation (`df$education_years`), revenu (`df$income`), type d'assurance médicale (`df$insurance_class`)
  - Cliniques : catégorie de maladie principale (`df$primary_disease_category`), catégorie de maladie secondaire (`df$secondary_disease_category`), 12 catégories de diagnostic d'admission (toutes les variables `df$diagnosis_`), score ADL (`df$adl_score`) et DASI 2 semaines (`df$DASI_score`) avant l'admission, statut non réanimatoire (`df$dnr_status`), cancer (`df$cancer`) (aucun, localisé, métastatique), estimation de la probabilité de survie à 2 mois (`df$survival_probability_2mths`), score APACHE (`df$apache_score`), score de Glasgow (`df$glasgow_score`), poids (`df$weight`), température (`df$temperature`), pression artérielle moyenne (`df$mean_blood_pressure`), fréquence respiratoire (`df$respiratory_rate`), fréquence cardiaque (`df$heart_rate`), rapport PaO2/FiO2 (`df$pa_fi_ratio`), PaCO2 (`df$paco2`), pH (`df$ph`), numération globulaire (WBC) (`df$wbc`), hématocrite (`df$hematocrit`), sodium (`df$sodium`), potassium (`df$potassium`), créatinine (`df$creatinine`), bilirubine (`df$bilirubin`), albumine (`df$albumin`), diurèse (`df$urine_output`) et 13 catégories de comorbidités (toutes les variables `df$comorbidity_`).
- On voit qu'ils ont inclu la diurèse et le score ADL dans leur modèle de propension, même si

ces variables avaient des taux de données manquantes très élevés (environ 75% pour le score ADL et 53% pour la diurèse).

— Concernant la gestion des données manquantes, les auteurs disent avoir supposé que les données manquantes pour le étaient des valeurs normales ("*Missing measurements were assumed to have normal values*"), ce qui correspond à une imputation simple (imputation par la valeur normale).

5.A.2 Choix dans notre analyse

— On propose d'inclure les mêmes variables que celles sélectionnées par les auteurs de l'article original (car étant identifiées par des experts).

— Pour la gestion des données manquantes avant appariement :

  — Une imputation est nécessaire si l'on veut inclure les variables avec des données manquantes dans le score de propension, car les méthodes d'appariement ne peuvent pas gérer les données manquantes.

  — Comme expliqué dans l'article de Eiset et Frydenberg (2022),[1], une imputation multiple n'est pas une bonne option dans ce cas car difficilement combinable avec un appariement : il faudrait gérer la multiplicité des jeux de données imputés et s'assurer que l'appariement est effectué de manière cohérente à travers les jeux (soit en calculant un score de propension moyen à travers les jeux, soit en réalisant l'appariement séparément dans chaque jeu puis en poolant les résultats).

  — On propose donc de réaliser une imputation simple par la médiane pour les deux variables avec des données manquantes (score ADL et diurèse), ce qui permettra de les inclure dans le score de propension sans complexifier l'analyse.

5.B Calcul du score de propension et appariement

— Paramètrage du score de propension :

  — Modèle de régression logistique avec comme variable dépendante la réalisation d'un RHC (variable `rhc`) et comme variables indépendantes les variables sélectionnées (toutes les variables listées ci-dessus).

  — Appariement 1 :1 sans remplacement (c'est à dire que chaque patient ayant eu un RHC est apparié à un seul patient n'ayant pas eu de RHC, et qu'un patient n'ayant pas eu de RHC ne peut être apparié qu'à un seul patient ayant eu un RHC)

  — Caliper = avec un caliper de $0,2 \times$ SD du score de propension (c'est à dire que les patients sont appariés uniquement s'ils ont des scores de propension qui diffèrent de moins de $0,2 \times$ écart type du score de propension)

    — Choix du Caliper basé sur Austin (2011)[2]

5.C Évaluation de l'équilibre des covariables après appariement et de la qualité de l'appariement

- L'évaluation de l'équilibre des covariables après appariement est essentielle pour vérifier que les groupes appariés sont comparables en termes de caractéristiques basales, ce qui est crucial pour réduire les biais de sélection et améliorer la validité des conclusions de l'étude.
- Pour ce devoir, elle suit les recommandations citées par Zhang et al. (2019)[3], Austin (2009)[4], Stuart et al. (2013)[5] et Imai et al. (2008)[6].

5.C.1 Histogramme de densité du score de propension avant et après appariement

- On peut visualiser l'équilibre du score de propension entre les groupes RHC et non-RHC avant et après appariement à l'aide d'un histogramme de densité du score de propension pour les deux groupes.
- Avant appariement, on s'attend à voir des distributions de score de propension différentes entre les groupes RHC et non-RHC, avec une distribution plus élevée de scores de propension dans le groupe RHC (car les patients ayant eu un RHC sont plus susceptibles d'avoir des caractéristiques associées à une probabilité plus élevée de recevoir un RHC).
- On utilise la fonction `bal.plot` du package `cobalt` pour créer ces graphiques.
  - la variable `distance` correspond au score de propension variant entre 0 et 1, calculé par `matchit` (variable `distance` dans l'objet `matchit_out`)
  - Treatment = 0 correspond au groupe non-RHC et Treatment = 1 correspond au groupe RHC

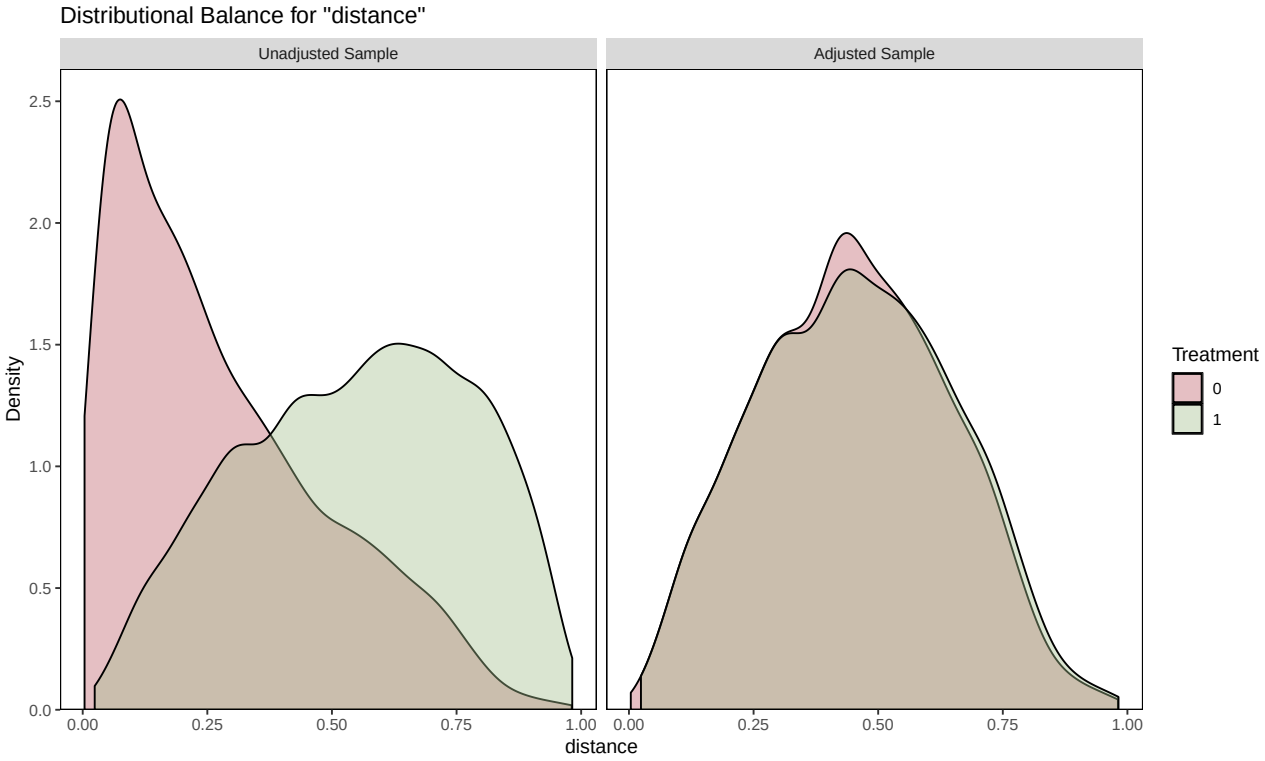

FIGURE 12 – Histogramme de densité du score de propension avant et après appariement. Distance correspond au score de propension variant entre 0 et 1 ; Treatment = 0 correspond au groupe non-RHC et Treatment = 1 correspond au groupe RHC

— On voit bien que la distribution du score de propension était différente avant appariement entre les groupes RHC et non-RHC, avec une distribution plus élevée de scores de propension dans le groupe RHC. Après appariement, les distributions sont beaucoup plus similaires entre les groupes, ce qui suggère que l'appariement a réussi à équilibrer les groupes en termes de score de propension.

5.C.2 Love plot des différences moyennes standardisées pour les variables basales après appariement

— Comme avant l'appariement, on peut visualiser l'équilibre des covariables basales entre les groupes RHC et non-RHC après appariement à l'aide d'un love plot, qui montre les différences moyennes standardisées (SMD) pour chaque variable basale entre les groupes.

— Après un appariement réussi, on s'attend à voir des SMD proches de 0 pour la plupart des variables, avec idéalement aucun SMD supérieur à 0.1 (ce qui correspond à une différence standardisée faible).

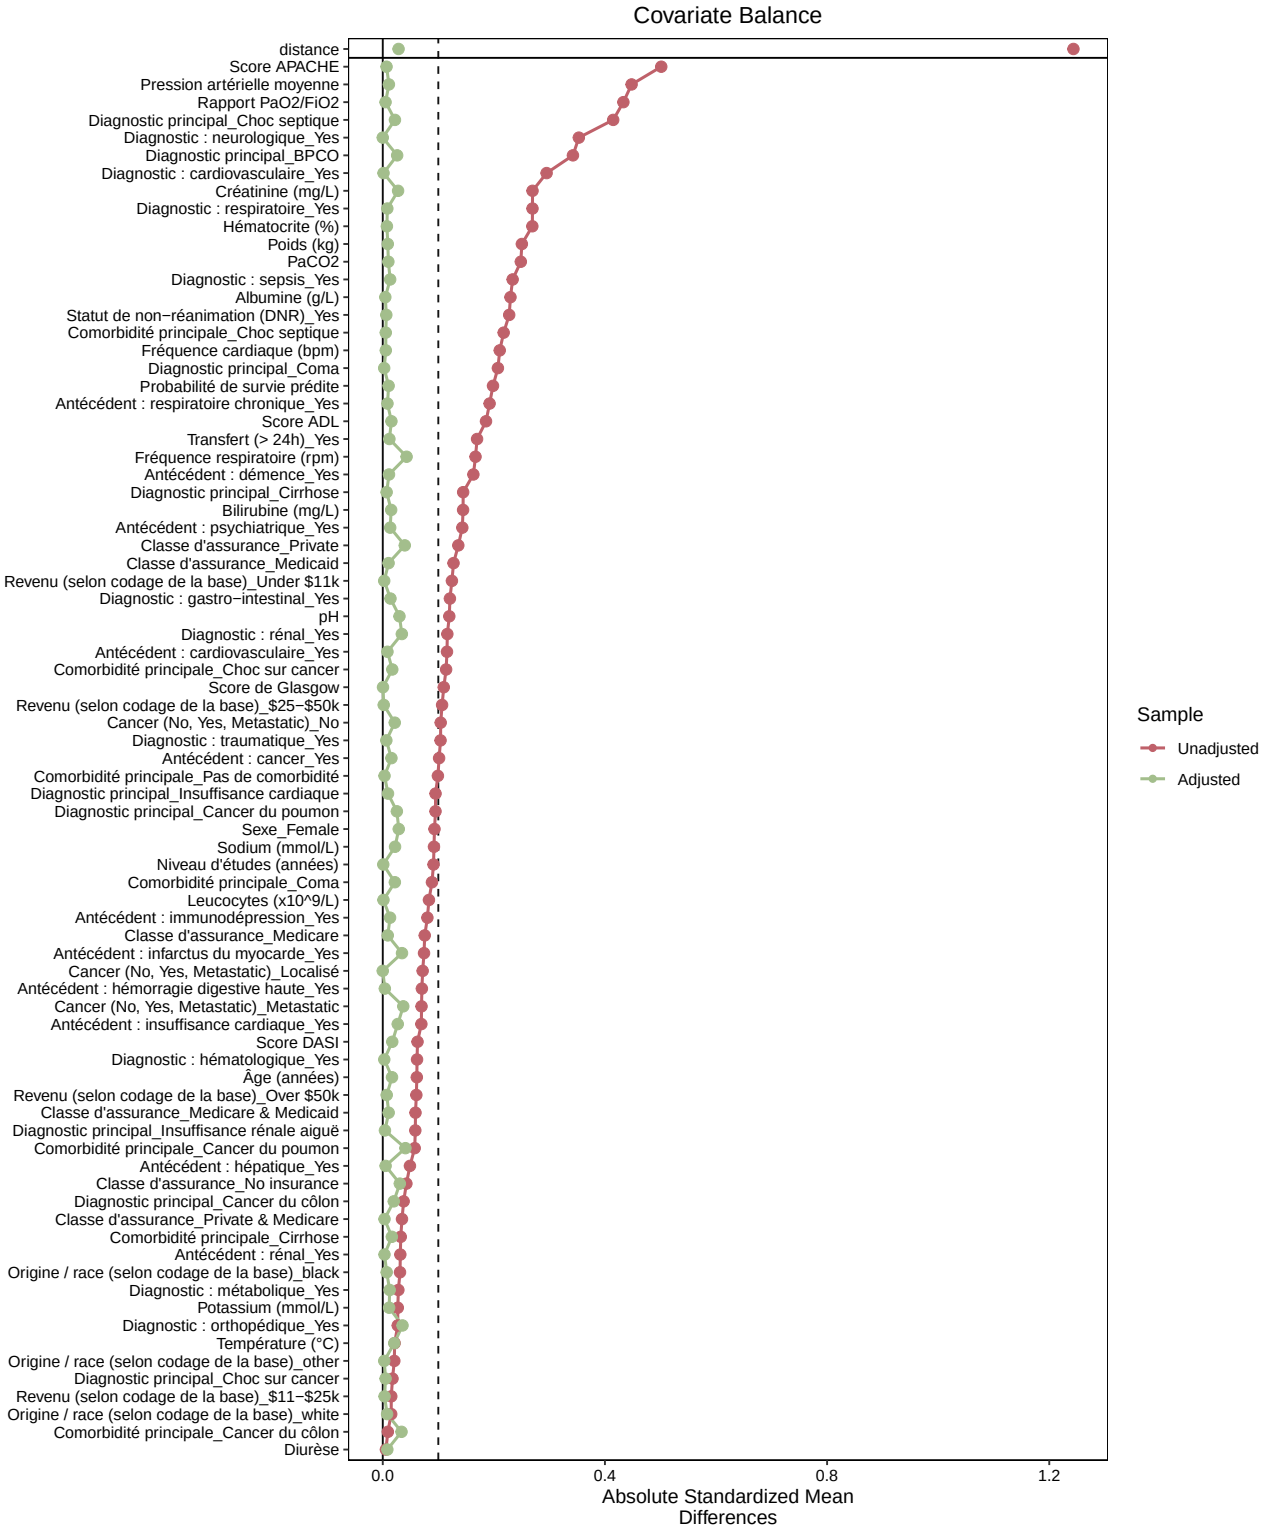

FIGURE 13 – Love plot visualisant les différences moyennes standardisées pour les variables basales après appariement (Seuil de 0.1)

Table 16 – Nombre de covariables avec |SMD| > 0,1 avant et après appariement

Avant_appariement	Apres_appariement
20	0

5.C.3 Tests comparatifs pour les variables basales après appariement

- Après appariement, on peut se poser la quesion de réaliser des tests comparatifs pour les variables basales afin de vérifier l'équilibre entre les groupes appariés.
- Cependant, comme on cherche à mettre en évidence l'absence de différence entre les groupes, les tests de significativité ne sont pas appropriés (les tests utilisés sont plutôt conçus pour détecter des différences).
- De plus, le fait que les groupes soient appariés signifie que les échantillons sont plus petits, ce qui réduit la puissance des tests statistiques pour détecter des différences, même si elles existent.

5.C.4 Conclusion sur l'évaluation de l'équilibre après appariement

- Au total, l'évaluation de l'équilibre des covariables après appariement suggère que l'appariement a réussi à équilibrer les groupes RHC et non-RHC en termes de caractéristiques basales, avec des distributions de score de propension similaires et des SMD < 0.1 pour toutes les variables basales après appariement.
- Cependant, il est important de noter que l'équilibre des covariables basales ne garantit pas l'absence de biais de sélection ou de confusion résiduelle, notamment du fait que certaines variables potentiellement confondantes n'ont pas été mesurées, donc pas incluses dans le score de propension.
- Ce n'est donc pas une preuve absolue de la comparabilité initiale des groupes, mais cela suggère que l'appariement a permis de réduire les différences observées entre les groupes en termes de caractéristiques basales.

6 Analyse après appariement

6.A Résultats

6.A.1 En utilisant des critères binaires (décès à 30 jours et à 180 jours)

Table 17 – Comparaison des décès à 30 jours et à 180 jours entre les groupes RHC vs non-RHC

Variable	**No RHC** N = 1,539[1]	**RHC** N = 1,539[1]	**p-value**[2]
Décès à 30 jours	484 (31%)	576 (37%)	<0.001
Décès à 180 jours	957 (62%)	1,048 (68%)	<0.001

[1] n (%)
[2] Pearson's Chi-squared test

Table 18 – Odds Ratio (OR) pour le décès à 30 jours et à 180 jours

Critère	OR	IC 95%
Décès à 30 jours	1.3	(1.12, 1.51)
Décès à 180 jours	1.3	(1.12, 1.51)

— Il y a significativement plus de décès à 30 jours et à 180 jours dans le groupe RHC que dans le groupe non-RHC ($p < 0.001$ pour les deux critères).

— Les OR sont de 1.3 pour le décès à 30 jours et de 1.3 pour le décès à 180 jours, indiquant une association positive entre le RHC et le risque de décès à ces deux critères.

6.A.2 En utilisant des critères de temps de survie (temps jusqu'au décès ou censure)

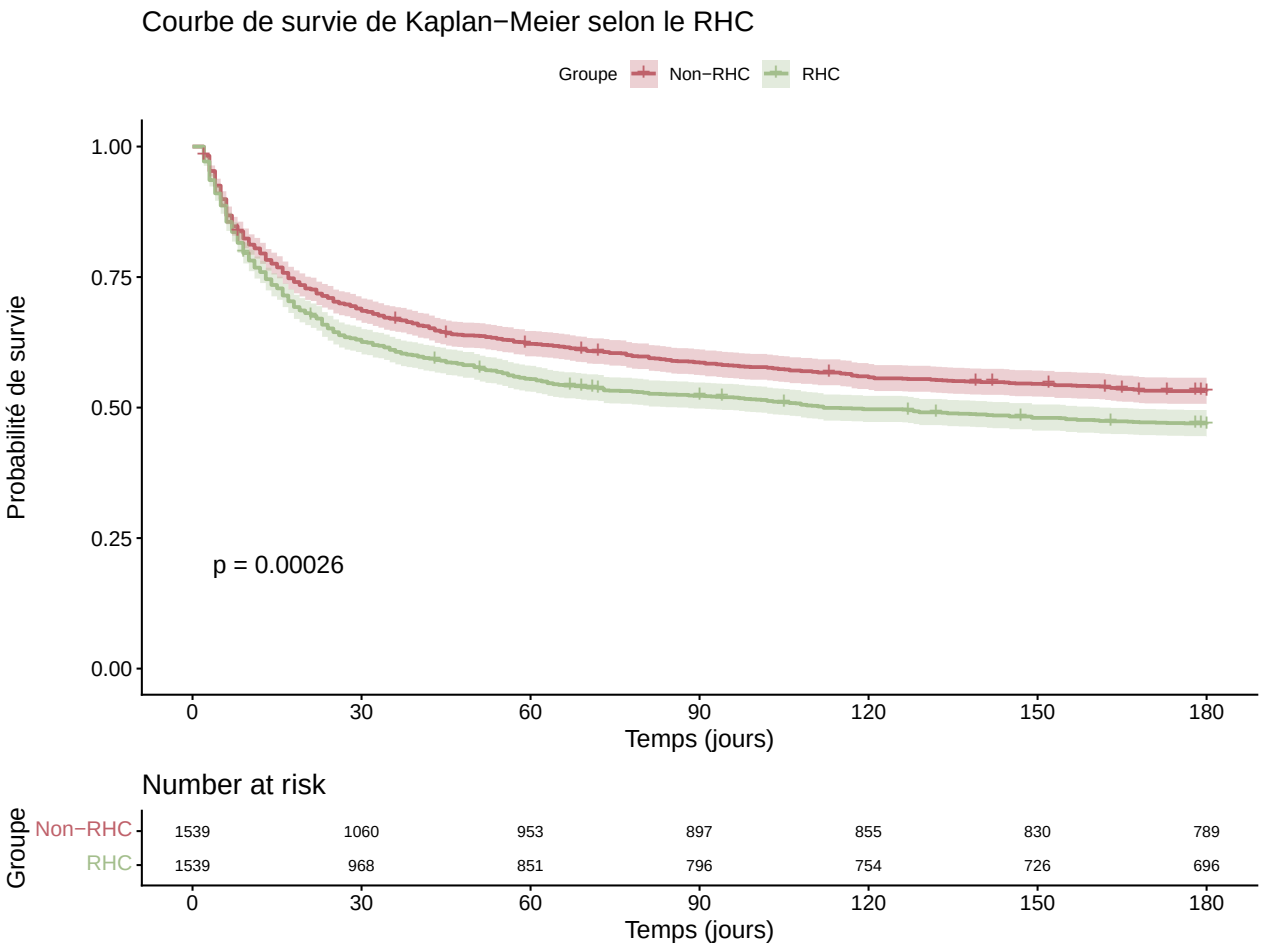

FIGURE 14 – Courbe de survie de Kaplan-Meier selon le RHC dans la population appariée

- Le test du log rank indique une différence significative entre les courbes de survie des groupes RHC et non-RHC ($p < 0.001$), suggérant une différence persistante entre les courbes de survie après appariement.
- L'hypothèse de proportionnalité des risques semble être vérifiée, car les courbes de survie ne se croisent pas et restent parallèles au fil du temps
- NB : le test du log-rank "conventionnel" n'est peut-être pas idéal dans le contexte de données appariées, car il ne prend pas en compte la structure de dépendance introduite par l'appariement. S'en suit un risque d'erreur de type 1 artificiellement bas, comme cité dans un autre article d'Austin (2013)[7]
- L'article recommande :
  - de réaliser un "log-rank stratifié sur les paires", qui est un test de rang qui prend en compte la structure de dépendance introduite par l'appariement en stratifiant les paires appariées.

— on pourra aussi réaliser un modèle de Cox avec estimation robuste de la variance. Nous utiliserons un estimateur sandwich (qui fonctionne en ajustant les erreurs standard pour tenir compte de la corrélation au sein des paires appariées) pour obtenir des intervalles de confiance et des p-values corrects.

6.A.3 Prise en compte de la structure de dépendance introduite par l'appariement dans les tests de survie

6.A.3.1 Test du log-rank conventionnel vs test du log-rank stratifié sur les paires

Table 19 – Résultats du test du log-rank conventionnel et du test du log-rank stratifié sur les paires

Test	p_value
Log-rank conventionnel	0.0002604
Log-rank stratifié	0.0015960

— Dans les 2 cas, le test du log-rank indique une différence significative entre les courbes de survie des groupes RHC et non-RHC, suggérant une différence persistante entre les courbes de survie après appariement, même en prenant en compte la structure de dépendance introduite par l'appariement.

6.A.3.2 Modèle de Cox stratifié sur les paires avec estimation robuste de la variance

Table 20 – Résultats du modèle de Cox stratifié sur les paires avec estimation robuste de la variance

Variable	HR	IC.95.	p_value
RHC vs No RHC	1.2	(1.09, 1.33)	<0.001

— Le modèle de Cox stratifié sur les paires avec estimation robuste de la variance indique que le RHC est associé à un risque de décès à 180 jours significativement plus élevé que le non-RHC.

— Le risque instantané de décès à 180 jours est multiplié par 1.2 chez les patients ayant eu un RHC par rapport à ceux n'ayant pas eu de RHC, avec un intervalle de confiance à 95% allant de et une p-value < 0.001.

— En détails :

  — Le clustering sur les paires permet de prendre en compte la structure de dépendance introduite par l'appariement, en ajustant les erreurs standard pour tenir compte de la corrélation au sein des paires appariées.

  — L'estimation robuste de la variance (estimateur sandwich) permet d'obtenir des intervalles de confiance et des p-values mieux estimés.

— Conditions de validité du modèle de Cox (par graphiques des résidus de Schoenfeld) :

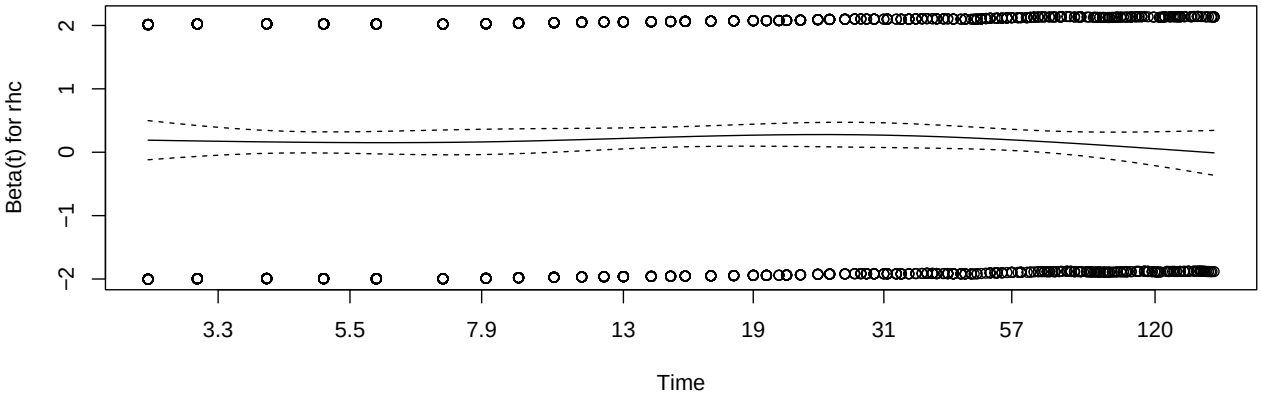

FIGURE 15 – Graphique des résidus de Schoenfeld pour vérifier l'hypothèse de proportionalité des risques

— Les résidus semblent stationnaires dans le temps, ce qui suggère que l'hypothèse de proportionalité des risques est vérifiée pour le modèle de Cox ajusté.

6.B Interprétation des résultats

— Après appariement, le cathéterisme cardiaque droit (RHC) est associé à un risque de décès à 30 jours et à 180 jours significativement plus élevé que le non-RHC.

— Les analyses de survie indiquent que les patients ayant eu un RHC ont une probabilité de survie à 180 jours significativement plus faible que les patients n'ayant pas eu de RHC, même après appariement.

7 Autre approche : analyse multivariée sur la population totale (non appariée)

7.A Principe

— L'analyse de survie multivariée sur la population totale (non appariée) permet d'estimer l'association entre le RHC et le risque de décès à 180 jours en ajustant pour les variables basales qui pourraient confondre cette association.

— Si l'association entre le RHC et le risque de décès à 180 jours reste significative après ajustement pour les variables basales, cela suggère que le RHC pourrait être associé à un risque de décès plus élevé indépendamment des caractéristiques basales des patients.

7.B Quelles variables inclure dans le modèle de survie multivarié ?

— On peut inclure dans le modèle de survie multivarié les mêmes variables basales que celles utilisées pour le score de propension, car ce sont des variables qui ont été identifiées par les auteurs de l'article original comme étant liées à la décision de réaliser un RHC.

— Un seuil de 10 événements par variable est recommandé pour éviter le sur-ajustement.

— Dans la cohorte totale avant appariement, 3722 patients sont décédés à 180 jours. En suivant la règle de 10 événements par variable, on pourrait inclure jusqu'à environ 372 variables dans le modèle de survie multivarié sans risque majeur de sur-ajustement.

7.C Mise en œuvre du modèle de survie multivarié

— On peut ajuster un modèle de Cox pour estimer l'association entre le RHC et le risque de décès à 180 jours, en incluant les variables basales comme covariables dans le modèle.

— Cela revient à inclure 84 variables basales (+ quelques "*dummy variables*" pour les catégories de variables catégorielles) dans le modèle de Cox, ce qui est faisable compte tenu du nombre d'événements disponibles.

Table 21 – Résultats du modèle de Cox multivarié ajusté pour les variables basales

Variable	HR	IC95	p_value
RHC vs No RHC	1.24	(1.14, 1.36)	< 0.001

— On trouve un risque instantané de décès à 180 jours multiplié par 1.24 chez les patients ayant eu un RHC par rapport à ceux n'ayant pas eu de RHC, avec un intervalle de confiance à 95% allant de (1.14, 1.36) et une p-value < 0.001.

— C'est très similaire aux résultats obtenus dans la population appariée !

7.D Interprétation des résultats du modèle de régression multivariée

— Le RHC est associé à un risque de décès à 180 jours significativement plus élevé que le non-RHC, même après ajustement pour les variables basales.

8 Conclusion

- Le cathéterisme cardiaque droit est associé à un risque de décès à 30 jours et à 180 jours significativement plus élevé que le non-RHC, que ce soit dans la population totale en analyse “brute”, dans une population appariée sur un score de propension, ou dans une analyse multivariée ajustée pour les variables basales.
- L’appariement a permis d’améliorer la comparabilité initiale des groupes ayant eu ou non un cathéterisme cardiaque droit en équilibrant les caractéristiques basales, mais il est important de noter que l’équilibre des covariables basales ne garantit pas l’absence de biais de sélection ou de confusion résiduelle, notamment du fait que certaines variables potentiellement confondantes n’ont pas été mesurées, donc pas incluses dans le score de propension.
- L’analyse multivariable ajustée pour les variables basales a permis d’estimer l’association entre le RHC et le risque de décès à 180 jours en ajustant pour les variables basales qui pourraient confondre cette association, et les résultats sont similaires à ceux obtenus dans la population appariée.
- Une randomisation *a priori*, c’est à dire avant la réalisation ou non du cathéterisme cardiaque droit, serait nécessaire pour mieux caractériser s’il existe une relation causale entre cathéterisme et risque de décès, en réduisant au maximum les biais de sélection et de confusion résiduels.

9 Bibliographie

[1] Andreas Halgreen Eiset and Morten Frydenberg. Considerations for Using Multiple Imputation in Propensity Score-Weighted Analysis – A Tutorial with Applied Example. *Clinical Epidemiology*, 14 :835–847, July 2022. ISSN 1179-1349. doi : 10.2147/CLEP.S354733.

[2] Peter C Austin. Optimal caliper widths for propensity-score matching when estimating differences in means and differences in proportions in observational studies. *Pharmaceutical Statistics*, 10(2) :150–161, March 2011. ISSN 1539-1604. doi : 10.1002/pst.433.

[3] Zhongheng Zhang, Hwa Jung Kim, Guillaume Lonjon, and Yibing Zhu. Balance diagnostics after propensity score matching. *Annals of Translational Medicine*, 7(1) :16, January 2019. ISSN 2305-5839. doi : 10.21037/atm.2018.12.10.

[4] Peter C. Austin. Balance diagnostics for comparing the distribution of baseline covariates between treatment groups in propensity-score matched samples. *Statistics in Medicine*, 28(25) : 3083–3107, 2009. ISSN 1097-0258. doi : 10.1002/sim.3697.

[5] Elizabeth A. Stuart, Brian K. Lee, and Finbarr P. Leacy. Prognostic score–based balance measures can be a useful diagnostic for propensity score methods in comparative effectiveness research. *Journal of Clinical Epidemiology*, 66(8, Supplement) :S84–S90.e1, August 2013. ISSN 0895-4356. doi : 10.1016/j.jclinepi.2013.01.013.

[6] Kosuke Imai, Gary King, and Elizabeth A. Stuart. Misunderstandings Between Experimentalists and Observationalists about Causal Inference. *Journal of the Royal Statistical Society Series A : Statistics in Society*, 171(2) :481–502, April 2008. ISSN 0964-1998. doi : 10.1111/j.1467-985X.2007.00527.x.

[7] Peter C Austin. The use of propensity score methods with survival or time-to-event outcomes : Reporting measures of effect similar to those used in randomized experiments. *Statistics in Medicine*, 33(7) :1242–1258, March 2014. ISSN 0277-6715. doi : 10.1002/sim.5984.

10 Annexes

10.A Tableau comparatif post-appariement

Variable	No RHC N = 1,539	RHC N = 1,539	p-value
Démographie / socio-économique			
Âge	61 (17)	61 (16)	0.6
Sexe			0.4
Male	889 (58%)	867 (56%)	
Female	650 (42%)	672 (44%)	
Ethnie			>0.9
black	244 (16%)	240 (16%)	
other	95 (6.2%)	94 (6.1%)	
white	1,200 (78%)	1,205 (78%)	
Années d'éducation	11.8 (3.2)	11.8 (3.1)	>0.9
Revenu			>0.9
Under $11k	827 (54%)	829 (54%)	
$11-$25k	314 (20%)	316 (21%)	
$25-$50k	265 (17%)	264 (17%)	
Over $50k	133 (8.6%)	130 (8.4%)	
Classe d'assurance			0.9
No insurance	83 (5.4%)	94 (6.1%)	
Medicaid	149 (9.7%)	154 (10%)	
Medicare	362 (24%)	368 (24%)	
Medicare & Medicaid	86 (5.6%)	90 (5.8%)	
Private	509 (33%)	481 (31%)	
Private & Medicare	350 (23%)	352 (23%)	
Statut fonctionnel / scores			
Score ADL	0.25 (0.93)	0.24 (0.94)	0.6
Score DASI	20.6 (5.4)	20.6 (5.1)	0.6
Score Coma	19 (28)	19 (28)	>0.9
Score APACHE	57 (20)	57 (20)	0.9
Statut DNR	126 (8.2%)	123 (8.0%)	0.8
Comorbidités			
Cardiopathie	313 (20%)	318 (21%)	0.8
Insuffisance cardiaque congestive	297 (19%)	313 (20%)	0.5
Infarctus du myocarde	48 (3.1%)	58 (3.8%)	0.3
Maladie pulmonaire chronique	227 (15%)	232 (15%)	0.8
Insuffisance rénale	80 (5.2%)	81 (5.3%)	>0.9
Insuffisance hépatique	105 (6.8%)	107 (7.0%)	0.9
Saignement GI supérieur	48 (3.1%)	47 (3.1%)	>0.9
Démence	115 (7.5%)	120 (7.8%)	0.7
Psychologique	75 (4.9%)	80 (5.2%)	0.7
Malignité	360 (23%)	350 (23%)	0.7
Immunosuppression	443 (29%)	434 (28%)	0.7
Transfert	190 (12%)	196 (13%)	0.7
Diagnostic principal (CAT1)			
BPCO	47 (3.1%)	57 (3.7%)	0.3
Choc septique	383 (25%)	369 (24%)	0.6
Choc sur cancer	124 (8.1%)	126 (8.2%)	0.9
Insuffisance rénale aiguë	683 (44%)	686 (45%)	>0.9
Insuffisance cardiaque	166 (11%)	170 (11%)	0.8
Coma	77 (5.0%)	78 (5.1%)	>0.9
Cirrhose	49 (3.2%)	47 (3.1%)	0.8
Cancer du poumon	8 (0.5%)	5 (0.3%)	0.4
Cancer du colon	2 (0.1%)	1 (<0.1%)	>0.9

(continued)

Variable	No RHC N = 1,539	RHC N = 1,539	p-value
Comorbidité principale (CAT2)			
Choc septique	263 (17%)	266 (17%)	0.9
Choc sur cancer	58 (3.8%)	53 (3.4%)	0.6
Coma	14 (0.9%)	18 (1.2%)	0.5
Cirrhose	11 (0.7%)	9 (0.6%)	0.7
Cancer du poumon	5 (0.3%)	2 (0.1%)	0.5
Cancer du colon	0 (0%)	1 (<0.1%)	>0.9
secondary_binaire_pas_de_comorbidite	1,188 (77%)	1,190 (77%)	>0.9
Diagnostics			
Diagnostic respiratoire	507 (33%)	501 (33%)	0.8
Diagnostic cardiovasculaire	583 (38%)	584 (38%)	>0.9
Diagnostic neurologique	112 (7.3%)	112 (7.3%)	>0.9
Diagnostic gastro-intestinal	280 (18%)	288 (19%)	0.7
Diagnostic rénal	82 (5.3%)	94 (6.1%)	0.4
Diagnostic métabolique	72 (4.7%)	68 (4.4%)	0.7
Diagnostic hématologique	97 (6.3%)	96 (6.2%)	>0.9
Diagnostic sepsis	332 (22%)	324 (21%)	0.7
Diagnostic traumatique	14 (0.9%)	15 (1.0%)	0.9
Diagnostic orthopédique	1 (<0.1%)	3 (0.2%)	0.6
Cancer			
Cancer (Oui/Non)	375 (24%)	361 (23%)	0.6
Type de cancer			0.6
No	1,164 (76%)	1,178 (77%)	
Localisé	266 (17%)	266 (17%)	
Metastatic	109 (7.1%)	95 (6.2%)	
Paramètres cliniques			
Poids	76 (20)	75 (18)	0.8
Pression artérielle moyenne	74 (34)	74 (34)	0.8
Fréquence cardiaque	121 (37)	121 (35)	0.9
Fréquence respiratoire	29 (13)	29 (14)	0.2
Température	37.66 (1.89)	37.62 (1.71)	0.6
Ratio Pa/FI	210 (108)	211 (108)	0.9
Diurèse	2,098 (1,080)	2,089 (1,130)	0.8
Biologie			
Globules blancs	16 (12)	16 (13)	>0.9
Albumine	3.04 (0.69)	3.04 (0.97)	>0.9
Hématocrite	31 (8)	31 (7)	0.8
Bilirubine	2.7 (5.7)	2.6 (5.3)	0.7
Créatinine	2.24 (2.30)	2.30 (1.97)	0.5
Sodium	137 (8)	137 (7)	0.5
Potassium	4.03 (1.03)	4.04 (0.99)	0.7
PaCO2	37 (11)	37 (11)	0.8
pH	7.39 (0.11)	7.39 (0.11)	0.4

[1] Mean (SD) ; n (%)

[2] Welch Two Sample t-test ; Pearson's Chi-squared test ; Fisher's exact test

10.B code R

```
library(forecast)
library(cobalt)
library(plotrix)
library(randomForest)
library(dplyr)
library(tidyr)
library(epiR)
library(viridisLite)
```

```r
library(ggplot2)
library(binom)
library(survminer)
library(pROC)
library(treemap)
library(psy)
library(MASS)
library(rpart)
library(rpart.plot)
library(plotly)
library(lmerTest)
library(psych)
library(lme4)
library(prettyR)
library(zoo)
library(kableExtra)
library(gtsummary)
library(lattice)
library(survey)
library(corrplot)
library(mice)
library(paletteer)
library(skimr)
library(nord)
library(wesanderson)
library(lubridate)
library(qgraph)
library(nlme)
library(pwr)
library(ape)
library(survival)
library(gmodels)
library(httpgd)
library(e1071)
library(psy)
library(reshape2)
knitr::opts_chunk$set(echo = TRUE)

#file_qmd <- "/Users/thomashusson/Documents/Projets/M2biostatistiques/devoir_stats_avancees/devoir_stats_
    avancees.qmd"

#extraction du code R pour le mettre à la fin du quarto md
detect_qmd_path <- function() {
   candidates <- c(
      knitr::current_input(),
      Sys.getenv("QUARTO_DOCUMENT_PATH", ""),
      Sys.getenv("QUARTO_INPUT_FILE", ""),
      "devoir_epidemio.qmd",
      file.path("S2", "devoir_epidemio", "devoir_epidemio.qmd")
   )
   candidates <- unique(candidates[nzchar(candidates)])
   for (p in candidates) {
      if (file.exists(p)) return(normalizePath(p, winslash = "/", mustWork = TRUE))
   }
   NA_character_
}

file_qmd <- detect_qmd_path()
if (is.na(file_qmd)) {
   warning("Extraction des chunks R sautée : impossible de localiser le .qmd (problème de working directory
       / IDE).")
} else {
   lines <- readLines(file_qmd, warn = FALSE)

   # trouver les débuts de chunks R
   starts <- grep("^```\\{r\\b", lines)
   code_r <- character(0)

   for (s in starts) {
      if (s >= length(lines)) next
      rel_end <- which(grepl("^```\\s*$", lines[(s + 1):length(lines)]))[1]
      if (is.na(rel_end)) {
         warning("Extraction des chunks R partielle : fin de chunk manquante après la ligne ", s, ".")
         next
      }
```

```r
      e <- s + rel_end

      # lignes à 'intérieur du chunk (excluant les balises de début et fin)
      chunk_lines <- lines[(s + 1):(e - 1)]

      # filtrer : garder seulement les lignes qui **ne sont pas des options Quarto**
      real_code <- chunk_lines[!grepl("^\\s*#\\|", chunk_lines)]
      code_r <- c(code_r, real_code, "")
   }

   outfile <- file.path(dirname(file_qmd), "all_chunks_code.R")
   cat(code_r, file = outfile, sep = "\n")
}

# Charger les données
df <- read.csv2("/Users/thomashusson/Documents/Projets/M2biostatistiques/S2/devoir_epidemio/rhc devoir
    épidémio-RC csv.csv", header = TRUE, stringsAsFactors = FALSE)
summary(df)
colnames(df)
skimr::skim(df)
sum(is.na(df))

# Supprimer les colonnes inutile (ROWNAMES et PTID) en appelant explictement les noms des colonnes à
    supprimer
df <- df[, !(colnames(df) %in% c("ROWNAMES", "PTID"))]
colnames(df)

# Renommer les colonnes
# syntaxe : names(df)[names(df) == "ANCIEN_NOM"] <- "NOUVEAU_NOM"
names(df)[names(df) == "CAT1"] <- "primary_disease_category"
names(df)[names(df) == "CAT2"] <- "secondary_disease_category"
names(df)[names(df) == "CA"] <- "cancer"
names(df)[names(df) == "SADMDTE"] <- "date_admission"
names(df)[names(df) == "DSCHDTE"] <- "date_discharge"
names(df)[names(df) == "DTHDTE"] <- "date_death"
names(df)[names(df) == "LSTCTDTE"] <- "date_last_news"
names(df)[names(df) == "DEATH"] <- "death_180d"

names(df)[names(df) == "CARDIOHX"] <- "comorbidity_cardiovascular"
names(df)[names(df) == "CHFHX"] <- "comorbidity_congestive_heart"
names(df)[names(df) == "DEMENTHX"] <- "comorbidity_dementia"
names(df)[names(df) == "PSYCHHX"] <- "comorbidity_psych"
names(df)[names(df) == "CHRPULHX"] <- "comorbidity_chronic_pulmonary"
names(df)[names(df) == "RENALHX"] <- "comorbidity_renal"
names(df)[names(df) == "LIVERHX"] <- "comorbidity_liver"
names(df)[names(df) == "GIBLEDHX"] <- "comorbidity_upper_gi_bleeding"
names(df)[names(df) == "MALIGHX"] <- "comorbidity_malignancy"
names(df)[names(df) == "IMMUNHX"] <- "comorbidity_immunosuppression"
names(df)[names(df) == "TRANSHX"] <- "comorbidity_transfer"
names(df)[names(df) == "AMIHX"] <- "comorbidity_myocardial_infarction"

names(df)[names(df) == "AGE"] <- "age"
names(df)[names(df) == "SEX"] <- "sex"
names(df)[names(df) == "EDU"] <- "education_years"
names(df)[names(df) == "SURV2MD1"] <- "survival_probability_2mths"
names(df)[names(df) == "DAS2D3PC"] <- "DASI_score"
names(df)[names(df) == "T3D30"] <- "time_to_death_if_death_within_30d"
names(df)[names(df) == "DTH30"] <- "death_30d"

names(df)[names(df) == "APS1"] <- "apache_score"
names(df)[names(df) == "SCOMA1"] <- "glasgow_score"
names(df)[names(df) == "MEANBP1"] <- "mean_blood_pressure"
names(df)[names(df) == "WBLC1"] <- "wbc"
names(df)[names(df) == "HRT1"] <- "heart_rate"
names(df)[names(df) == "RESP1"] <- "respiratory_rate"
names(df)[names(df) == "TEMP1"] <- "temperature"
names(df)[names(df) == "PAFI1"] <- "pa_fi_ratio"
names(df)[names(df) == "ALB1"] <- "albumin"
names(df)[names(df) == "HEMA1"] <- "hematocrit"
names(df)[names(df) == "BILI1"] <- "bilirubin"
names(df)[names(df) == "CREA1"] <- "creatinine"
names(df)[names(df) == "SOD1"] <- "sodium"
names(df)[names(df) == "POT1"] <- "potassium"
names(df)[names(df) == "PACO21"] <- "paco2"
names(df)[names(df) == "PH1"] <- "ph"

names(df)[names(df) == "SWANG1"] <- "rhc"
```

```r
names(df)[names(df) == "WTKILO1"] <- "weight"
names(df)[names(df) == "DNR1"] <- "dnr_status"
names(df)[names(df) == "NINSCLAS"] <- "insurance_class"

names(df)[names(df) == "RESP"] <- "diagnosis_respiratory"
names(df)[names(df) == "CARD"] <- "diagnosis_cardiovascular"
names(df)[names(df) == "NEURO"] <- "diagnosis_neurological"
names(df)[names(df) == "GASTR"] <- "diagnosis_gastrointestinal"
names(df)[names(df) == "RENAL"] <- "diagnosis_renal"
names(df)[names(df) == "META"] <- "diagnosis_metabolic"
names(df)[names(df) == "HEMA"] <- "diagnosis_hematologic"
names(df)[names(df) == "SEPS"] <- "diagnosis_sepsis"
names(df)[names(df) == "TRAUMA"] <- "diagnosis_trauma"
names(df)[names(df) == "ORTHO"] <- "diagnosis_orthopedic"

names(df)[names(df) == "ADLD3P"] <- "adl_score"
names(df)[names(df) == "URIN1"] <- "urine_output"
names(df)[names(df) == "RACE"] <- "race"
names(df)[names(df) == "INCOME"] <- "income"

# Ajout d'une description des variables
desc <- c(
  primary_disease_category = "Diagnostic principal",
  secondary_disease_category = "Comorbidité principale",
  cancer = "Cancer (No, Yes, Metastatic)",
  date_admission = "Date d'admission",
  date_discharge = "Date de sortie",
  date_death = "Date de décès",
  date_last_news = "Date des dernières nouvelles",
  death_180d = "Décès à 180 jours (Yes/No)",

  comorbidity_cardiovascular = "Antécédent : cardiovasculaire",
  comorbidity_congestive_heart = "Antécédent : insuffisance cardiaque",
  comorbidity_dementia = "Antécédent : démence",
  comorbidity_psych = "Antécédent : psychiatrique",
  comorbidity_chronic_pulmonary = "Antécédent : respiratoire chronique",
  comorbidity_renal = "Antécédent : rénal",
  comorbidity_liver = "Antécédent : hépatique",
  comorbidity_upper_gi_bleeding = "Antécédent : hémorragie digestive haute",
  comorbidity_malignancy = "Antécédent : cancer",
  comorbidity_immunosuppression = "Antécédent : immunodépression",
  comorbidity_transfer = "Transfert (> 24h)",
  comorbidity_myocardial_infarction = "Antécédent : infarctus du myocarde",

  age = "Âge (années)",
  sex = "Sexe",
  education_years = "Niveau d'études (années)",
  survival_probability_2mths = "Probabilité de survie prédite",
  DASI_score = "Score DASI",
  death_30d = "Décès à 30 jours",

  apache_score = "Score APACHE",
  glasgow_score = "Score de Glasgow",
  mean_blood_pressure = "Pression artérielle moyenne",
  wbc = "Leucocytes (x10^9/L)",
  heart_rate = "Fréquence cardiaque (bpm)",
  respiratory_rate = "Fréquence respiratoire (rpm)",
  temperature = "Température (°C)",
  pa_fi_ratio = "Rapport PaO2/FiO2",
  albumin = "Albumine (g/L)",
  hematocrit = "Hématocrite (%)",
  bilirubin = "Bilirubine (mg/L)",
  creatinine = "Créatinine (mg/L)",
  sodium = "Sodium (mmol/L)",
  potassium = "Potassium (mmol/L)",
  paco2 = "PaCO2",
  ph = "pH",

  rhc = "Cathétérisme cardiaque droit (RHC)",
  weight = "Poids (kg)",
  dnr_status = "Statut de non-réanimation (DNR)",
  insurance_class = "Classe d'assurance",

  diagnosis_respiratory = "Diagnostic : respiratoire",
  diagnosis_cardiovascular = "Diagnostic : cardiovasculaire",
  diagnosis_neurological = "Diagnostic : neurologique",
  diagnosis_gastrointestinal = "Diagnostic : gastro-intestinal",
```

```r
  diagnosis_renal = "Diagnostic : rénal",
  diagnosis_metabolic = "Diagnostic : métabolique",
  diagnosis_hematologic = "Diagnostic : hématologique",
  diagnosis_sepsis = "Diagnostic : sepsis",
  diagnosis_trauma = "Diagnostic : traumatique",
  diagnosis_orthopedic = "Diagnostic : orthopédique",

  adl_score = "Score ADL",
  urine_output = "Diurèse",
  race = "Origine / race (selon codage de la base)",
  income = "Revenu (selon codage de la base)"
)

missing_data_summary <- data.frame(
  variable = names(colSums(is.na(df))),
  missing_nombre = colSums(is.na(df)),
  missing_pourcentage = round(colSums(is.na(df)) / nrow(df) * 100, 1)
)
missing_data_summary <- missing_data_summary[missing_data_summary$missing_nombre > 0, ]
#affichage du tableau des données manquantes avec kableExtra pour un rendu plus lisible
missing_data_summary %>%
  arrange(desc(missing_pourcentage)) %>%
  kable(
    caption = "Résumé des données manquantes par variable",
    col.names = c("Variable", "Nombre de données manquantes", "Pourcentage de données manquantes"),
    align = c("l", "r", "r"),
    row.names = FALSE
  ) %>%
  kable_styling(full_width = FALSE, position = "center")


# Conversion des dates (les chaînes vides -> NA pour éviter les warnings)
df$date_admission[df$date_admission == ""] <- NA
df$date_discharge[df$date_discharge == ""] <- NA
df$date_death[df$date_death == ""] <- NA
df$date_last_news[df$date_last_news == ""] <- NA

# Conversion en format date
df$date_admission <- as.Date(df$date_admission, format = "%d/%m/%Y")
df$date_discharge <- as.Date(df$date_discharge, format = "%d/%m/%Y")
df$date_death <- as.Date(df$date_death, format = "%d/%m/%Y")
df$date_last_news <- as.Date(df$date_last_news, format = "%d/%m/%Y")

str(df$date_death)
df$date_death <- as.Date(df$date_death, format = "%d/%m/%Y")
str(df$date_death)

# Facteurs et numériques
df$death_180d <- factor(df$death_180d, levels = c("No", "Yes"))

df$primary_disease_category <- factor(
   df$primary_disease_category,
   levels = c("COPD","MOSF w/Sepsis","MOSF w/Malignancy","ARF","CHF","Coma","Cirrhosis","Lung Cancer","Colon
         Cancer"),
   labels = c("BPCO","Choc septique","Choc sur cancer","Insuffisance rénale aiguë","Insuffisance cardiaque",
        "Coma","Cirrhose","Cancer du poumon","Cancer du côlon")
   )
unique(df$primary_disease_category)
table(df$primary_disease_category)

df$secondary_disease_category <- factor(
   df$secondary_disease_category,
   levels = c("", "MOSF w/Sepsis","MOSF w/Malignancy", "Coma","Cirrhosis","Lung Cancer","Colon Cancer"),
   labels = c("Pas de comorbidité","Choc septique","Choc sur cancer", "Coma","Cirrhose","Cancer du poumon","
        Cancer du côlon")
   )

df$comorbidity_cardiovascular <- factor(df$comorbidity_cardiovascular, levels = c(0, 1), labels = c("No", "
     Yes"))
df$comorbidity_congestive_heart <- factor(df$comorbidity_congestive_heart, levels = c(0, 1), labels = c("No"
     , "Yes"))
df$comorbidity_dementia <- factor(df$comorbidity_dementia, levels = c(0, 1), labels = c("No", "Yes"))
df$comorbidity_psych <- factor(df$comorbidity_psych, levels = c(0, 1), labels = c("No", "Yes"))
df$comorbidity_chronic_pulmonary <- factor(df$comorbidity_chronic_pulmonary, levels = c(0, 1), labels = c("
     No", "Yes"))
df$comorbidity_renal <- factor(df$comorbidity_renal, levels = c(0, 1), labels = c("No", "Yes"))
df$comorbidity_liver <- factor(df$comorbidity_liver, levels = c(0, 1), labels = c("No", "Yes"))
```

```r
df$comorbidity_upper_gi_bleeding <- factor(df$comorbidity_upper_gi_bleeding, levels = c(0, 1), labels = c("
    No", "Yes"))
df$comorbidity_malignancy <- factor(df$comorbidity_malignancy, levels = c(0, 1), labels = c("No", "Yes"))
df$comorbidity_immunosuppression <- factor(df$comorbidity_immunosuppression, levels = c(0, 1), labels = c("
    No", "Yes"))
df$comorbidity_transfer <- factor(df$comorbidity_transfer, levels = c(0, 1), labels = c("No", "Yes"))
df$comorbidity_myocardial_infarction <- factor(df$comorbidity_myocardial_infarction, levels = c(0, 1),
    labels = c("No", "Yes"))
#recodage de la variable cancer (No, Yes, Metastatic en No, Localisé, Metastatic)
df$cancer <- factor(df$cancer, levels = c("No", "Yes", "Metastatic"), labels = c("No", "Localisé", "
    Metastatic"))
#créer une variable binaire pour le cancer (Yes/No) à partir de la variable cancer (No, Localisé, Metastatic
    , codé Yes si Localisé ou Metastatic, No sinon)
df$cancer_YN <- ifelse(df$cancer %in% c("Localisé", "Metastatic"), "Yes", "No")
table(df$cancer_YN)
df$sex <- factor(df$sex, levels = c("Male", "Female"))
df$death_30d <- factor(df$death_30d, levels = c("No", "Yes"))
df$apache_score <- as.numeric(df$apache_score)
df$glasgow_score <- as.numeric(df$glasgow_score)
df$heart_rate <- as.numeric(df$heart_rate)
df$sodium <- as.numeric(df$sodium)
df$dnr_status <- factor(df$dnr_status, levels = c("No", "Yes"))
df$insurance_class <- factor(
   df$insurance_class,
   levels = c(
      "No insurance",
      "Medicaid",
      "Medicare",
      "Medicare & Medicaid",
      "Private",
      "Private & Medicare"
   )
)
df$diagnosis_respiratory <- factor(df$diagnosis_respiratory, levels = c("No", "Yes"))
df$diagnosis_cardiovascular <- factor(df$diagnosis_cardiovascular, levels = c("No", "Yes"))
df$diagnosis_neurological <- factor(df$diagnosis_neurological, levels = c("No", "Yes"))
df$diagnosis_gastrointestinal <- factor(df$diagnosis_gastrointestinal, levels = c("No", "Yes"))
df$diagnosis_renal <- factor(df$diagnosis_renal, levels = c("No", "Yes"))
df$diagnosis_metabolic <- factor(df$diagnosis_metabolic, levels = c("No", "Yes"))
df$diagnosis_hematologic <- factor(df$diagnosis_hematologic, levels = c("No", "Yes"))
df$diagnosis_sepsis <- factor(df$diagnosis_sepsis, levels = c("No", "Yes"))
df$diagnosis_trauma <- factor(df$diagnosis_trauma, levels = c("No", "Yes"))
df$diagnosis_orthopedic <- factor(df$diagnosis_orthopedic, levels = c("No", "Yes"))
df$adl_score <- as.numeric(df$adl_score)
df$race <- factor(df$race)
df$income <- as.character(df$income)
df$income[df$income == "> $50k"] <- "Over $50k"
df$income <- factor(df$income, levels = c("Under $11k", "$11-$25k", "$25-$50k", "Over $50k"))
df$rhc <- factor(df$rhc, levels = c("No RHC", "RHC"))

#recodage en binaire des primary_disease_category et secondary_disease_category (présence ou absence de
    chaque catégorie de maladie)
df$primary_binaire_BPCO <- ifelse(df$primary_disease_category == "BPCO", "Yes", "No")
df$primary_binaire_choc_septique <- ifelse(df$primary_disease_category == "Choc septique", "Yes", "No")
df$primary_binaire_choc_sur_cancer <- ifelse(df$primary_disease_category == "Choc sur cancer", "Yes", "No")
df$primary_binaire_insuffisance_renale_aigue <- ifelse(df$primary_disease_category == "Insuffisance rénale
    aiguë", "Yes", "No")
df$primary_binaire_insuffisance_cardiaque <- ifelse(df$primary_disease_category == "Insuffisance cardiaque",
     "Yes", "No")
df$primary_binaire_coma <- ifelse(df$primary_disease_category == "Coma", "Yes", "No")
df$primary_binaire_cirrhose <- ifelse(df$primary_disease_category == "Cirrhose", "Yes", "No")
df$primary_binaire_cancer_du_poumon <- ifelse(df$primary_disease_category == "Cancer du poumon", "Yes", "No"
    )
df$primary_binaire_cancer_du_colon <- ifelse(df$primary_disease_category == "Cancer du côlon", "Yes", "No")
#recodage de la variable secondary_disease_category en binaire (présence ou absence de chaque catégorie de
    maladie)
df$secondary_binaire_choc_septique <- ifelse(df$secondary_disease_category == "Choc septique", "Yes", "No")
df$secondary_binaire_choc_sur_cancer <- ifelse(df$secondary_disease_category == "Choc sur cancer", "Yes", "
    No")
df$secondary_binaire_coma <- ifelse(df$secondary_disease_category == "Coma", "Yes", "No")
df$secondary_binaire_cirrhose <- ifelse(df$secondary_disease_category == "Cirrhose", "Yes", "No")
df$secondary_binaire_cancer_du_poumon <- ifelse(df$secondary_disease_category == "Cancer du poumon", "Yes",
    "No")
df$secondary_binaire_cancer_du_colon <- ifelse(df$secondary_disease_category == "Cancer du côlon", "Yes", "
    No")
```

```r
df$secondary_binaire_pas_de_comorbidite <- ifelse(df$secondary_disease_category == "Pas de comorbidité", "
    Yes", "No")
str(df)

#vérification du format des datese
is.Date(df$date_death)
is.Date(df$date_last_news)
# Vérification de la cohérence entre date_death et date_last_news pour les patients décédés
incoherent_death_dates <- df$death_180d == "Yes" & df$date_death != df$date_last_news
sum(incoherent_death_dates) # Nombre de cas incohérents

# Correction des dates incohérentes
df$date_last_news[incoherent_death_dates] <- df$date_death[incoherent_death_dates]
# Vérification après correction
incoherent_death_dates_after <- df$death_180d == "Yes" & df$date_death != df$date_last_news
sum(incoherent_death_dates_after) # Nombre de cas incohérents après correction (devrait être 0)

# vérification du format des dates
is.Date(df$date_discharge)
is.Date(df$date_last_news)
# Vérification de la cohérence entre date_discharge et date_last_news
incoherent_discharge_dates <- df$date_discharge > df$date_last_news
sum(incoherent_discharge_dates) # Nombre de cas incohérents

# Vérification du patient avec date de sortie d'hospitalisation inconnue
patient_missing_discharge <- is.na(df$date_discharge)
sum(patient_missing_discharge) # Nombre de patients avec date de sortie d'hospitalisation inconnue
# Vérification du statut de décès de ce patient
if (df$death_180d[patient_missing_discharge] == "Yes") {
   df$date_death[patient_missing_discharge]
} else {
   cat("Le patient n'est pas décédé)")
}
# Calcul de la différence entre la date de décès et la date d'admission pour ce patient
days_missing_discharge <- as.numeric(df$date_death[patient_missing_discharge] - df$date_admission[patient_
    missing_discharge])
days_missing_discharge


n_rows <- nrow(df)
n_cols <- ncol(df)

tab <- data.frame(
   Nom = "df",
   "Nombre d'observations" = n_rows,
   "Nombre de variables" = n_cols,
   check.names = FALSE
)

knitr::kable(tab, booktabs = TRUE)

col_type <- sapply(df, function(x) class(x)[1])
col_type[col_type %in% c("Date", "POSIXct", "POSIXlt")] <- "Date"
col_type[col_type %in% c("factor", "ordered")] <- "factor"
col_type[col_type %in% c("numeric", "integer")] <- "numeric"

type_freq <- sort(table(col_type), decreasing = TRUE)
type_freq_str <- paste(names(type_freq), as.integer(type_freq), sep = " : ", collapse = ", ")

tab <- data.frame(
   Type = names(type_freq),
   `Nombre` = as.integer(type_freq),
   check.names = FALSE
)
knitr::kable(tab, booktabs = TRUE)

cat_cols <- names(col_type)[col_type == "factor"]
cat_cols <- intersect(cat_cols, names(df))
cat_vars_df <- data.frame(
   Variable = cat_cols,
   check.names = FALSE,
   Description = desc[cat_cols],
   row.names = NULL
)
knitr::kable(cat_vars_df, booktabs = TRUE)

# Séparation des variables catégorielles en sous-catégories thématiques
cat_cols_disease_category <- grep("disease_category", cat_cols, value = TRUE)
```

```r
cat_cols_cancer <- grep("cancer", cat_cols, value = TRUE)
cat_cols_comorbidity <- grep("comorbidity", cat_cols, value = TRUE)
cat_cols_diagnosis <- grep("diagnosis", cat_cols, value = TRUE)
cat_cols_death <- grep("death", cat_cols, value = TRUE)
cat_cols_demographic <- c("sex", "dnr_status", "insurance_class", "race", "income")
cat_cols_RHC <- grep("rhc", cat_cols, value = TRUE)


# Création de deux barplots côte à côte pour les variables de catégorie de maladie principale et de
     comorbidité principale
df_descriptif <- df

# Calcul des effectifs pour les catégories de maladie principale et de comorbidité principale
counts_primary <- sort(table(df_descriptif$primary_disease_category), decreasing = FALSE)
counts_secondary <- sort(table(df_descriptif$secondary_disease_category), decreasing = FALSE)

# Disposition côte à côte des barplots
op <- par(no.readonly = TRUE)
on.exit(par(op), add = TRUE)
par(mfrow = c(1, 2))
par(mai = c(0.9, 1.75, 0.9, 0.25)) # marge gauche fixe (à ajuster)

# Création des barplots
barplot(
   counts_primary,
   names.arg = names(counts_primary),
   main = "Diagnostic principal",
   xlab = "Nombre de patients",
   horiz = TRUE,
   col = nord::nord("frost", length(counts_primary)),
   las = 2,
   cex.names = 0.75,
   cex.axis = 0.8,
   cex.lab = 0.9,
   cex.main = 0.9
)

barplot(
   counts_secondary,
   names.arg = names(counts_secondary),
   main = "Comorbidité principale",
   xlab = "Nombre de patients",
   horiz = TRUE,
   col = nord::nord("aurora", length(counts_secondary)),
   las = 2,
   cex.names = 0.75,
   cex.axis = 0.8,
   cex.lab = 0.9,
   cex.main = 0.9
)

# Bar plot pour chacun des diagnostics
par(op, no.readonly = TRUE) # réinitialiser les paramètres graphiques
par(mfrow = c(2, 5))
barplot(
   table(df$diagnosis_respiratory, useNA = "ifany"),
   main = "Respiratoire",
   col = nord::nord("frost", length(table(df$diagnosis_respiratory, useNA = "ifany"))),
   border = NA
   )
barplot(
   table(df$diagnosis_cardiovascular, useNA = "ifany"),
   main = "Cardiovasculaire",
   col = nord::nord("frost", length(table(df$diagnosis_cardiovascular, useNA = "ifany"))),
   border = NA
   )
barplot(
   table(df$diagnosis_neurological, useNA = "ifany"),
   main = "Neurologique",
   col = nord::nord("frost", length(table(df$diagnosis_neurological, useNA = "ifany"))),
   border = NA
   )
barplot(
   table(df$diagnosis_gastrointestinal, useNA = "ifany"),
   main = "Gastro-intestinal",
   col = nord::nord("frost", length(table(df$diagnosis_gastrointestinal, useNA = "ifany"))),
   border = NA
```

```
   )
barplot(
   table(df$diagnosis_renal, useNA = "ifany"),
   main = "Rénal",
   col = nord::nord("frost", length(table(df$diagnosis_renal, useNA = "ifany"))),
   border = NA
   )
barplot(
   table(df$diagnosis_metabolic, useNA = "ifany"),
   main = "Métabolique",
   col = nord::nord("frost", length(table(df$diagnosis_metabolic, useNA = "ifany"))),
   border = NA
   )
barplot(
   table(df$diagnosis_hematologic, useNA = "ifany"),
   main = "Hématologique",
   col = nord::nord("frost", length(table(df$diagnosis_hematologic, useNA = "ifany"))),
   border = NA
   )
barplot(
   table(df$diagnosis_sepsis, useNA = "ifany"),
   main = "Sepsis",
   col = nord::nord("frost", length(table(df$diagnosis_sepsis, useNA = "ifany"))),
   border = NA
   )
barplot(
   table(df$diagnosis_trauma, useNA = "ifany"),
   main = "Trauma",
   col = nord::nord("frost", length(table(df$diagnosis_trauma, useNA = "ifany"))),
   border = NA
   )
barplot(
   table(df$diagnosis_orthopedic, useNA = "ifany"),
   main = "Orthopédique",
   col = nord::nord("frost", length(table(df$diagnosis_orthopedic, useNA = "ifany"))),
   border = NA
   )

# Bar plot pour chacune des comorbidités
par(op, no.readonly = TRUE) # réinitialiser les paramètres graphiques
par(mfrow = c(3, 4))
barplot(
   table(df$comorbidity_cardiovascular, useNA = "ifany"),
   main = "Cardiovasculaire",
   col = nord::nord("aurora", length(table(df$comorbidity_cardiovascular, useNA = "ifany"))),
   border = NA
   )
barplot(
   table(df$comorbidity_congestive_heart, useNA = "ifany"),
   main = "Insuffisance cardiaque",
   col = nord::nord("aurora", length(table(df$comorbidity_congestive_heart, useNA = "ifany"))),
   border = NA
   )
barplot(
   table(df$comorbidity_dementia, useNA = "ifany"),
   main = "Démence",
   col = nord::nord("aurora", length(table(df$comorbidity_dementia, useNA = "ifany"))),
   border = NA
   )
barplot(
   table(df$comorbidity_psych, useNA = "ifany"),
   main = "Psychiatrique",
   col = nord::nord("aurora", length(table(df$comorbidity_psych, useNA = "ifany"))),
   border = NA
   )
barplot(
   table(df$comorbidity_chronic_pulmonary, useNA = "ifany"),
   main = "Respiratoire chronique",
   col = nord::nord("aurora", length(table(df$comorbidity_chronic_pulmonary, useNA = "ifany"))),
   border = NA
   )
barplot(
   table(df$comorbidity_renal, useNA = "ifany"),
   main = "Rénal",
   col = nord::nord("aurora", length(table(df$comorbidity_renal, useNA = "ifany"))),
```

```r
   border = NA
   )
barplot(
   table(df$comorbidity_liver, useNA = "ifany"),
   main = "Hépatique",
   col = nord::nord("aurora", length(table(df$comorbidity_liver, useNA = "ifany"))),
   border = NA
   )
barplot(
   table(df$comorbidity_upper_gi_bleeding, useNA = "ifany"),
   main = "Hémorragie digestive haute",
   col = nord::nord("aurora", length(table(df$comorbidity_upper_gi_bleeding, useNA = "ifany"))),
   border = NA
   )
barplot(
   table(df$comorbidity_malignancy, useNA = "ifany"),
   main = "Cancer",
   col = nord::nord("aurora", length(table(df$comorbidity_malignancy, useNA = "ifany"))),
   border = NA
   )
barplot(
   table(df$comorbidity_immunosuppression, useNA = "ifany"),
   main = "Immunodépression",
   col = nord::nord("aurora", length(table(df$comorbidity_immunosuppression, useNA = "ifany"))),
   border = NA
   )
barplot(
   table(df$comorbidity_transfer, useNA = "ifany"),
   main = "Transfert (> 24h)",
   col = nord::nord("aurora", length(table(df$comorbidity_transfer, useNA = "ifany"))),
   border = NA
   )
barplot(
   table(df$comorbidity_myocardial_infarction, useNA = "ifany"),
   main = "Infarctus du myocarde",
   col = nord::nord("aurora", length(table(df$comorbidity_myocardial_infarction, useNA = "ifany"))),
   border = NA
   )


cat_cols_comorbidity <- grep("comorbidity", cat_cols, value = TRUE)
cat_cols_diagnosis <- grep("diagnosis", cat_cols, value = TRUE)

# création des matrices dans CE chunk
comorbidity_matrix <- as.matrix(df[cat_cols_comorbidity]) == "Yes"
diagnosis_matrix <- as.matrix(df[cat_cols_diagnosis]) == "Yes"

n <- nrow(df)
bg_grey <- "grey92"

op <- par(no.readonly = TRUE)
on.exit(par(op), add = TRUE)
par(mfrow = c(1, 2))
par(mai = c(0.9, 2.4, 0.9, 0.25)) # un peu plus de marge pour des libellés longs

yes_c <- sort(colSums(comorbidity_matrix, na.rm = TRUE), decreasing = FALSE)

lab_c <- unname(desc[names(yes_c)])
lab_c <- gsub("^Antécédent\\s*:?\\s*", "", lab_c)

barplot(
  rep(n, length(yes_c)),
  names.arg = lab_c,
  main = "Comorbidités",
  xlab = "Nombre de patients",
  horiz = TRUE,
  col = bg_grey,
  border = NA,
  las = 2,
  cex.names = 0.75,
  cex.axis = 0.8,
  cex.lab = 0.9,
  cex.main = 0.9,
  xlim = c(0, n)
)

barplot(
```

```r
  yes_c,
  horiz = TRUE,
  col = nord::nord("frost", length(yes_c)),
  border = NA,
  add = TRUE,
  axes = FALSE,
  names.arg = rep("", length(yes_c))
)

# ---- Diagnostics ----
yes_d <- sort(colSums(diagnosis_matrix, na.rm = TRUE), decreasing = FALSE)

lab_d <- unname(desc[names(yes_d)])
lab_d <- gsub("^Diagnostic\\s*:\\s*", "", lab_d)

barplot(
  rep(n, length(yes_d)),
  names.arg = lab_d,
  main = "Diagnostics",
  xlab = "Nombre de patients",
  horiz = TRUE,
  col = bg_grey,
  border = NA,
  las = 2,
  cex.names = 0.75,
  cex.axis = 0.8,
  cex.lab = 0.9,
  cex.main = 0.9,
  xlim = c(0, n)
)

barplot(
  yes_d,
  horiz = TRUE,
  col = nord::nord("aurora", length(yes_d)),
  border = NA,
  add = TRUE,
  axes = FALSE,
  names.arg = rep("", length(yes_d))
)

op <- par(no.readonly = TRUE)
on.exit(par(op), add = TRUE)
par(mfrow = c(2, 3))

barplot(
   table(df$sex, useNA = "ifany"),
   main = "Sexe",
   col = nord::nord("frost", length(table(df$sex, useNA = "ifany"))),
   border = NA,
   las = 1,
   cex.names = 0.8
   )
barplot(
   table(df$dnr_status, useNA = "ifany"),
   main = "Non-réanimatoire",
   col = nord::nord("frost", length(table(df$dnr_status, useNA = "ifany"))),
   border = NA,
   las = 1,
   cex.names = 0.8
   )
barplot(
   table(df$race, useNA = "ifany"),
   main = "Origine / race",
   col = nord::nord("frost", length(table(df$race, useNA = "ifany"))),
   border = NA,
   las = 1,
   cex.names = 0.6
   )

par(mar = c(4, 12, 3, 1) + 0.1)
barplot(
   table(df$insurance_class, useNA = "ifany"),
   main = "Assurance",
   col = nord::nord("frost", length(table(df$insurance_class, useNA = "ifany"))),
   border = NA,
   horiz = TRUE,
```

```r
   las = 1,
   cex.names = 0.8
   )

barplot(
   table(df$income, useNA = "ifany"),
   main = "Revenu",
   col = nord::nord("frost", length(table(df$income, useNA = "ifany"))),
   border = NA,
   horiz = TRUE,
   las = 1,
   cex.names = 0.8
   )

# avec pourcentage et effectifs
cancer_yes_count <- sum(df$cancer_YN == "Yes", na.rm = TRUE)
cancer_yes_percentage <- round(mean(df$cancer_YN == "Yes", na.rm = TRUE) * 100, 1)
cancer_localized_count <- sum(df$cancer == "Localisé", na.rm = TRUE)
cancer_metastatic_count <- sum(df$cancer == "Metastatic", na.rm = TRUE)
cancer_localized_percentage <- round(cancer_localized_count / sum(df$cancer_YN == "Yes", na.rm = TRUE) *
     100, 1)
cancer_metastatic_percentage <- round(cancer_metastatic_count / sum(df$cancer_YN == "Yes", na.rm = TRUE) *
     100, 1
)
cancer_summary_df <- data.frame(
   `Variable` = c("Cancer (Yes/No)", "Cancer localisé", "Cancer métastatique"),
   `Pourcentage` = c(paste0(cancer_yes_percentage, "%"), paste0(cancer_localized_percentage, "%"), paste0(
        cancer_metastatic_percentage, "%")),
   `Effectifs` = c(paste0(cancer_yes_count, "/", nrow(df)), paste0(cancer_localized_count, "/", sum(df$
        cancer_YN == "Yes", na.rm = TRUE)), paste0(cancer_metastatic_count, "/", sum(df$cancer_YN == "Yes",
        na.rm = TRUE))),
   check.names = FALSE
)
knitr::kable(cancer_summary_df, booktabs = TRUE)

barplot(
   table(df$cancer, useNA = "ifany"),
   col = nord::nord("lumina", length(table(df$cancer, useNA = "ifany"))),
   border = NA,
   las = 1,
   cex.names = 0.8
   )

par(op, no.readonly = TRUE) # réinitialiser les paramètres graphiques
par(mfrow = c(1, 2))
barplot(
   table(df$death_30d, useNA = "ifany"),
   main = "Décès à 30 jours",
   col = nord::nord("baie_mouton", length(table(df$death_30d, useNA = "ifany"))),
   border = NA,
   las = 1,
   cex.names = 0.8
   )
barplot(
   table(df$death_180d, useNA = "ifany"),
   main = "Décès à 180 jours",
   col = nord::nord("baie_mouton", length(table(df$death_180d, useNA = "ifany"))),
   border = NA,
   las = 1,
   cex.names = 0.8
)

death_30d_percentage <- round(mean(df$death_30d == "Yes", na.rm = TRUE) * 100, 1)
death_180d_percentage <- round(mean(df$death_180d == "Yes", na.rm = TRUE) * 100, 1)
# affichage aussi des effectifs dans une colonne (n/N)
death_30d_count <- sum(df$death_30d == "Yes", na.rm = TRUE)
death_30d_total <- sum(!is.na(df$death_30d))
death_180d_count <- sum(df$death_180d == "Yes", na.rm = TRUE)
death_180d_total <- sum(!is.na(df$death_180d))
death_summary_df <- data.frame(
   `Variable` = c("Décès à 30 jours", "Décès à 180 jours"),
   `Pourcentage` = c(paste0(death_30d_percentage, "%"), paste0(death_180d_percentage, "%")),
   `Effectifs` = c(paste0(death_30d_count, "/", death_30d_total), paste0(death_180d_count, "/", death_180d_
        total)),
   check.names = FALSE
)
```

```r
knitr::kable(death_summary_df, booktabs = TRUE)

barplot(
   table(df$rhc, useNA = "ifany"),
   col = nord::nord("lumina", length(table(df$rhc, useNA = "ifany"))),
   border = NA,
   las = 1,
   cex.names = 0.8
   )

rhc_percentage <- round(mean(df$rhc == "RHC", na.rm = TRUE) * 100, 1)
rhc_count <- sum(df$rhc == "RHC", na.rm = TRUE)
rhc_total <- sum(!is.na(df$rhc))
rhc_summary_df <- data.frame(
   `Variable` = "Cathéterisme cardiaque droit (RHC)",
   `Pourcentage` = paste0(rhc_percentage, "%"),
   `Effectifs` = paste0(rhc_count, "/", rhc_total),
   check.names = FALSE
)
knitr::kable(rhc_summary_df, booktabs = TRUE)

# tableau avec moyenne, SD, médiane, Q1, Q3, min et max pour chacune des variables numériques
numeric_cols <- names(col_type)[col_type == "numeric"]
numeric_cols <- setdiff(numeric_cols, "time_to_death_if_death_within_30d")

#création du tableau récapitulatif des variables numériques
numeric_summary_df <- data.frame(
   Variables = desc[numeric_cols],
   Moyenne = sapply(df[numeric_cols], function(x) round(mean(x, na.rm = TRUE), 2)),
   SD = sapply(df[numeric_cols], function(x) round(sd(x, na.rm = TRUE), 2)),
   Médiane = sapply(df[numeric_cols], function(x) round(median(x, na.rm = TRUE), 2)),
   Q1 = sapply(df[numeric_cols], function(x) round(quantile(x, 0.25, na.rm = TRUE), 2)),
   Q3 = sapply(df[numeric_cols], function(x) round(quantile(x, 0.75, na.rm = TRUE), 2)),
   Min = sapply(df[numeric_cols], function(x) round(min(x, na.rm = TRUE), 2)),
   Max = sapply(df[numeric_cols], function(x) round(max(x, na.rm = TRUE), 2)),
   check.names = FALSE
)

#affichage du tableau
knitr::kable(
   numeric_summary_df,
   booktabs = FALSE,
   row.names = FALSE
) %>%
  kableExtra::column_spec(1, width = "6cm")

# quel pourcentage les valeurs 0 représentent-elles pour chacune de ces variables ?
outlier_summary_df <- data.frame(
   Variable = c("Pression artérielle moyenne", "Leucocytose", "Fréquence cardiaque", "Fréquence respiratoire
        ", "Poids"),
   "Valeur aberrante" = c(sum(df$mean_blood_pressure == 0, na.rm = TRUE), sum(df$wbc == 0, na.rm = TRUE),
        sum(df$heart_rate == 0, na.rm = TRUE), sum(df$respiratory_rate == 0, na.rm = TRUE), sum(df$weight ==
         0, na.rm = TRUE)),
   "Pourcentage de valeurs 0" = c(round(mean(df$mean_blood_pressure == 0, na.rm = TRUE) * 100, 2), round(
        mean(df$wbc == 0, na.rm = TRUE) * 100, 2), round(mean(df$heart_rate == 0, na.rm = TRUE) * 100, 2),
        round(mean(df$respiratory_rate == 0, na.rm = TRUE) * 100, 2), round(mean(df$weight == 0, na.rm =
        TRUE) * 100, 2))
)

#affichage du tableau
knitr::kable(outlier_summary_df, booktabs = TRUE)

# imputation des valeurs 0 par la médiane de chaque variable
df$mean_blood_pressure[df$mean_blood_pressure == 0] <- median(df$mean_blood_pressure[df$mean_blood_pressure
     > 0], na.rm = TRUE)
df$wbc[df$wbc == 0] <- median(df$wbc[df$wbc > 0], na.rm = TRUE)
df$heart_rate[df$heart_rate == 0] <- median(df$heart_rate[df$heart_rate > 0], na.rm = TRUE)
df$respiratory_rate[df$respiratory_rate == 0] <- median(df$respiratory_rate[df$respiratory_rate > 0], na.rm
     = TRUE)
df$weight[df$weight == 0] <- median(df$weight[df$weight > 0], na.rm = TRUE)

# tableau avec moyenne, SD, médiane, Q1, Q3, min et max pour chacune des variables numériques après
     imputation
numeric_cols_imputed <- c(
  "mean_blood_pressure",
  "wbc",
  "heart_rate",
```

```r
  "respiratory_rate",
  "weight"
)

numeric_summary_imputed_df <- data.frame(
  Variables = numeric_cols_imputed,
  Moyenne = sapply(df[numeric_cols_imputed], function(x) round(mean(x, na.rm = TRUE), 2)),
  SD = sapply(df[numeric_cols_imputed], function(x) round(sd(x, na.rm = TRUE), 2)),
  Médiane = sapply(df[numeric_cols_imputed], function(x) round(median(x, na.rm = TRUE), 2)),
  Q1 = sapply(df[numeric_cols_imputed], function(x) round(quantile(x, 0.25, na.rm = TRUE), 2)),
  Q3 = sapply(df[numeric_cols_imputed], function(x) round(quantile(x, 0.75, na.rm = TRUE), 2)),
  Min = sapply(df[numeric_cols_imputed], function(x) round(min(x, na.rm = TRUE), 2)),
  Max = sapply(df[numeric_cols_imputed], function(x) round(max(x, na.rm = TRUE), 2)),
  check.names = FALSE
)

knitr::kable(
  numeric_summary_imputed_df,
  booktabs = FALSE,
  row.names = FALSE
) %>%
  kableExtra::column_spec(1, width = "6cm")


knitr::kable(
   numeric_summary_imputed_df,
   booktabs = FALSE,
   row.names = FALSE
) %>%
  kableExtra::column_spec(1, width = "6cm")

numeric_cols <- names(col_type)[col_type == "numeric"]

op <- par(no.readonly = TRUE)
on.exit(par(op), add = TRUE)

cols <- viridisLite::viridis(n = max(length(numeric_cols), 1), begin = 0.1, end = 0.95)

par(mfrow = c(4, 6), mar = c(4, 4, 2, 1))

hist(
  df$age,
  breaks = 20,
  main = "Âge",
  xlab = "Âge",
  ylab = "Fréquence",
  col = cols[1],
  border = TRUE,
  freq = FALSE
)
lines(density(df$age, na.rm = TRUE), col = "blue", lwd = 2)
hist(
  df$education_years,
  breaks = 20,
  main = "Années d'éducation",
  xlab = "Années d'éducation",
  ylab = "Fréquence",
  col = cols[2],
  border = TRUE,
  freq = FALSE
)
lines(density(df$education_years, na.rm = TRUE), col = "blue", lwd = 2)
hist(
  df$survival_probability_2mths,
  breaks = 20,
  main = "Probabilité de survie",
  xlab = "Probabilité de survie",
  ylab = "Fréquence",
  col = cols[3],
  border = TRUE,
  freq = FALSE
)
lines(density(df$survival_probability_2mths, na.rm = TRUE), col = "blue", lwd = 2)
hist(
  df$DASI_score,
  breaks = 20,
  main = "Score DASI",
```

```
  xlab = "Score DASI",
  ylab = "Fréquence",
  col = cols[4],
  border = TRUE,
  freq = FALSE
)
lines(density(df$DASI_score, na.rm = TRUE), col = "blue", lwd = 2)
hist(
  df$apache_score,
  breaks = 20,
  main = "Score APACHE",
  xlab = "Score APACHE",
  ylab = "Fréquence",
  col = cols[6],
  border = TRUE,
  freq = FALSE
)
lines(density(df$apache_score, na.rm = TRUE), col = "blue", lwd = 2)
hist(
  df$glasgow_score,
  breaks = 20,
  main = "score de Glasgow",
  xlab = "score de Glasgow",
  ylab = "Fréquence",
  col = cols[7],
  border = TRUE,
  freq = FALSE
)
lines(density(df$glasgow_score, na.rm = TRUE), col = "blue", lwd = 2)
hist(
  df$mean_blood_pressure,
  breaks = 20,
  main = "PA moyenne",
  xlab = "PA moyenne (mmHg)",
  ylab = "Fréquence",
  col = cols[8],
  border = TRUE,
  freq = FALSE
)
lines(density(df$mean_blood_pressure, na.rm = TRUE), col = "blue", lwd = 2)
hist(
  df$wbc,
  breaks = 20,
  main = "Leucocytose ",
  xlab = "Leucocytose (10^3/µL)",
  ylab = "Fréquence",
  col = cols[9],
  border = TRUE,
  freq = FALSE
)
lines(density(df$wbc, na.rm = TRUE), col = "blue", lwd = 2)
hist(
  df$heart_rate,
  breaks = 20,
  main = "Pouls",
  xlab = "Pouls (bpm)",
  ylab = "Fréquence",
  col = cols[10],
  border = TRUE,
  freq = FALSE
)
lines(density(df$heart_rate, na.rm = TRUE), col = "blue", lwd = 2)
hist(
  df$respiratory_rate,
  breaks = 20,
  main = "Fréquence respiratoire",
  xlab = "FR (resp/min)",
  ylab = "Fréquence",
  col = cols[11],
  border = TRUE,
  freq = FALSE
)
lines(density(df$respiratory_rate, na.rm = TRUE), col = "blue", lwd = 2)
hist(
  df$temperature,
```

```
  breaks = 20,
  main = "Température",
  xlab = "T (°C)",
  ylab = "Fréquence",
  col = cols[12],
  border = TRUE,
  freq = FALSE
)
lines(density(df$temperature, na.rm = TRUE), col = "blue", lwd = 2)
hist(
  df$pa_fi_ratio,
  breaks = 20,
  main = "PaO2/FiO2",
  xlab = "PaO2/FiO2",
  ylab = "Fréquence",
  col = cols[13],
  border = TRUE,
  freq = FALSE
)
lines(density(df$pa_fi_ratio, na.rm = TRUE), col = "blue", lwd = 2)
hist(
  df$albumin,
  breaks = 20,
  main = "Albuminémie",
  xlab = "Albuminémie (g/dL)",
  ylab = "Fréquence",
  col = cols[14],
  border = TRUE,
  freq = FALSE
)
lines(density(df$albumin, na.rm = TRUE), col = "blue", lwd = 2)
hist(
  df$hematocrit,
  breaks = 20,
  main = "Hématocrite",
  xlab = "Hématocrite (%)",
  ylab = "Fréquence",
  col = cols[15],
  border = TRUE,
  freq = FALSE
)
lines(density(df$hematocrit, na.rm = TRUE), col = "blue", lwd = 2)
hist(
  df$bilirubin,
  breaks = 20,
  main = "Bilirubinémie",
  xlab = "Bilirubine (µmol/L)",
  ylab = "Fréquence",
  col = cols[16],
  border = TRUE,
  freq = FALSE
)
lines(density(df$bilirubin, na.rm = TRUE), col = "blue", lwd = 2)
hist(
  df$creatinine,
  breaks = 20,
  main = "Créatininémie",
  xlab = "Créatinine (µmol/L)",
  ylab = "Fréquence",
  col = cols[17],
  border = TRUE,
  freq = FALSE
)
lines(density(df$creatinine, na.rm = TRUE), col = "blue", lwd = 2)
hist(
  df$sodium,
  breaks = 20,
  main = "Natrémie",
  xlab = "Natrémie (mmol/L)",
  ylab = "Fréquence",
  col = cols[18],
  border = TRUE,
  freq = FALSE
)
lines(density(df$sodium, na.rm = TRUE), col = "blue", lwd = 2)
```

```r
hist(
  df$potassium,
  breaks = 20,
  main = "Kalémie",
  xlab = "Kalémie (mmol/L)",
  ylab = "Fréquence",
  col = cols[19],
  border = TRUE,
  freq = FALSE
)
lines(density(df$potassium, na.rm = TRUE), col = "blue", lwd = 2)
hist(
  df$paco2,
  breaks = 20,
  main = "PaCO2",
  xlab = "PaCO2 (mmHg)",
  ylab = "Fréquence",
  col = cols[20],
  border = TRUE,
  freq = FALSE
)
lines(density(df$paco2, na.rm = TRUE), col = "blue", lwd = 2)
hist(
  df$ph,
  breaks = 20,
  main = "pH",
  xlab = "pH",
  ylab = "Fréquence",
  col = cols[21],
  border = TRUE,
  freq = FALSE
)
lines(density(df$ph, na.rm = TRUE), col = "blue", lwd = 2)
hist(
  df$weight,
  breaks = 20,
  main = "Poids",
  xlab = "Poids (kg)",
  ylab = "Fréquence",
  col = cols[22],
  border = TRUE,
  freq = FALSE
)
lines(density(df$weight, na.rm = TRUE), col = "blue", lwd = 2)
hist(
  df$adl_score,
  breaks = 20,
  main = "Score ADL",
  xlab = "Score ADL",
  ylab = "Fréquence",
  col = cols[23],
  border = TRUE,
  freq = FALSE
)
lines(density(df$adl_score, na.rm = TRUE), col = "blue", lwd = 2)
hist(
  df$urine_output,
  breaks = 20,
  main = "Diurèse",
  xlab = "Diurèse (mL)",
  ylab = "Fréquence",
  col = cols[24],
  border = TRUE,
  freq = FALSE
)
lines(density(df$urine_output, na.rm = TRUE), col = "blue", lwd = 2)

qqnorm(
   df$age,
   main = "QQ-plot pour l'âge"
)
qqline(df$age, col = "red", lwd = 2)

# avec pourcentage de décès à 30 jours et à 180 jours dans les groupes R
# utilisation de tbl_summary de gtsummary pour faire un tableau comparatif des décès à 30 jours et à 180
     jours entre les groupes RHC vs non-RHC
```

```r
summary_table <- df %>%
  select(rhc, death_30d, death_180d) %>%
  tbl_summary(
    by = rhc,
    statistic = list(
      death_30d ~ "{n} ({p}%)",
      death_180d ~ "{n} ({p}%)"
    ),
    label = list(
      death_30d ~ "Décès à 30 jours",
      death_180d ~ "Décès à 180 jours"
    ),
    missing = "no"
  ) %>%
  add_p() %>%
  modify_header(label = "**Variable**")
summary_table

# calcul de l'OR pour le décès à 30 jours
or_30d <- epitools::oddsratio(
  x = table(df$rhc, df$death_30d),
  method = "wald",
  conf.level = 0.95
)
# calcul de l'OR pour le décès à 180 jours
or_180d <- epitools::oddsratio(
  x = table(df$rhc, df$death_180d),
  method = "wald",
  conf.level = 0.95
)
# création d'un tableau récapitulatif des OR
or_summary_df <- data.frame(
  `Critère` = c("Décès à 30 jours", "Décès à 180 jours"),
  `OR` = c(round(or_30d$measure[2, "estimate"], 2), round(or_180d$measure[2, "estimate"], 2)),
  "IC 95%" = c(
    paste0("(", round(or_30d$measure[2, "lower"], 2), ", ", round(or_30d$measure[2, "upper"], 2), ")"),
    paste0("(", round(or_180d$measure[2, "lower"], 2), ", ", round(or_180d$measure[2, "upper"], 2), ")")
  ),
  check.names = FALSE
)
knitr::kable(or_summary_df, booktabs = TRUE)

# Recalcul des temps à partir des dates (suivi "complet")
df$time_to_death <- as.numeric(df$date_death - df$date_admission)
df$time_to_last_news <- as.numeric(df$date_last_news - df$date_admission)

# Événement "décès" selon la présence d'une date de décès
df$event_death <- as.integer(!is.na(df$date_death))

# Temps de suivi complet (décès -> date_death, sinon -> date_last_news)
df$followup_time <- df$time_to_last_news

# Si décès, temps de suivi = temps jusqu'au décès
df$followup_time[df$event_death == 1] <- df$time_to_death[df$event_death == 1]

# Temps d'inclusion : prend le minimum entre le temps de suivi et 180 jours (donc censure après 180 jours)
df$survival_time_180d <- pmin(df$followup_time, 180)

# Événement "décès" à 180 jours : vaut 1 si décès ET temps jusqu'au décès <= 180 jours
df$event_180d <- as.integer(df$event_death == 1 & df$time_to_death <= 180)

# Temps négatifs -> NA
df$survival_time_180d[df$survival_time_180d < 0] <- NA

# création de l'objet de survie
surv_object <- Surv(time = df$survival_time_180d, event = df$event_180d)
# ajustement du modèle de survie de Kaplan-Meier
km_fit <- survfit(surv_object ~ rhc, data = df)
# affichage du graphique de survie
km_plot <- ggsurvplot(
  km_fit,
  data = df,
  pval = TRUE,
  conf.int = TRUE,
  risk.table = TRUE,
  risk.table.height = 0.2,
  risk.table.fontsize = 3.2,
```

```r
  break.time.by = 30,
  xlim = c(0, 180),
  legend.labs = c("Non-RHC", "RHC"),
  legend.title = "Groupe",
  xlab = "Temps (jours)",
  ylab = "Probabilité de survie",
  title = "Courbe de survie de Kaplan-Meier selon le RHC",
  palette = c(nord::nord("aurora")[1], nord::nord("aurora")[4])
)
print(km_plot)

# utilisation de tbl_summary de gtsummary pour faire un tableau comparatif des caractéristiques basales
    entre les groupes RHC vs non-RHC
# regroupement des variables
primary_columns <- grep("^(primary_binaire_|secondary_binaire_)", names(df), value = TRUE)
vars_demo <- c("age", "sex", "race", "education_years", "income", "insurance_class")
vars_scores <- c("adl_score", "DASI_score", "glasgow_score", "apache_score", "dnr_status")
vars_comorb <- c(
  "comorbidity_cardiovascular",
  "comorbidity_congestive_heart",
  "comorbidity_myocardial_infarction",
  "comorbidity_chronic_pulmonary",
  "comorbidity_renal",
  "comorbidity_liver",
  "comorbidity_upper_gi_bleeding",
  "comorbidity_dementia",
  "comorbidity_psych",
  "comorbidity_malignancy",
  "comorbidity_immunosuppression",
  "comorbidity_transfer"
)
vars_diag_other <- c(
  "diagnosis_respiratory",
  "diagnosis_cardiovascular",
  "diagnosis_neurological",
  "diagnosis_gastrointestinal",
  "diagnosis_renal",
  "diagnosis_metabolic",
  "diagnosis_hematologic",
  "diagnosis_sepsis",
  "diagnosis_trauma",
  "diagnosis_orthopedic"
)
vars_cancer <- c("cancer_YN", "cancer")
vars_clinical <- c(
  "weight", "mean_blood_pressure", "heart_rate",
  "respiratory_rate", "temperature", "pa_fi_ratio",
  "urine_output"
)
vars_bio <- c(
  "wbc", "albumin", "hematocrit", "bilirubin",
  "creatinine", "sodium", "potassium", "paco2", "ph"
)

# colonnes à inclure
cols_to_include_baseline <- c(
  vars_demo,
  vars_scores,
  vars_comorb,
  primary_columns,
  vars_diag_other,
  vars_cancer,
  vars_clinical,
  vars_bio
)

df_baseline_tbl <- df[, unique(c("rhc", cols_to_include_baseline))]

# répartition des variables en sous groupes pour la mise en forme du tableau
primary_binaire_columns <- grep("^primary_binaire_", primary_columns, value = TRUE)
secondary_binaire_columns <- grep("^secondary_binaire_", primary_columns, value = TRUE)

var_to_section <- c(
  stats::setNames(rep("Démographie / socio-économique", length(vars_demo)), vars_demo),
  stats::setNames(rep("Statut fonctionnel / scores", length(vars_scores)), vars_scores),
  stats::setNames(rep("Comorbidités", length(vars_comorb)), vars_comorb),
  stats::setNames(rep("Diagnostic principal (CAT1)", length(primary_binaire_columns)), primary_binaire_
```

```r
      columns),
  stats::setNames(rep("Comorbidité principale (CAT2)", length(secondary_binaire_columns)), secondary_binaire
      _columns),
  stats::setNames(rep("Diagnostics", length(vars_diag_other)), vars_diag_other),
  stats::setNames(rep("Cancer", length(vars_cancer)), vars_cancer),
  stats::setNames(rep("Paramètres cliniques", length(vars_clinical)), vars_clinical),
  stats::setNames(rep("Biologie", length(vars_bio)), vars_bio)
)

# Tableau avec gtsummary
baseline_comparison_table <- gtsummary::tbl_summary(
  df_baseline_tbl,
  by = "rhc",
  missing = "no",
  statistic = list(
    gtsummary::all_continuous() ~ "{mean} ({sd})",
    gtsummary::all_categorical() ~ "{n} ({p}%)"
  ),
  label = list(
    age ~ "Âge",
    sex ~ "Sexe",
    race ~ "Ethnie",
    education_years ~ "Années d'éducation",
    income ~ "Revenu",
    insurance_class ~ "Classe d'assurance",
    adl_score ~ "Score ADL",
    DASI_score ~ "Score DASI",
    glasgow_score ~ "Score Coma",
    apache_score ~ "Score APACHE",
    dnr_status ~ "Statut DNR",
    primary_binaire_BPCO ~ "BPCO",
    primary_binaire_choc_septique ~ "Choc septique",
    primary_binaire_choc_sur_cancer ~ "Choc sur cancer",
    primary_binaire_insuffisance_renale_aigue ~ "Insuffisance rénale aiguë",
    primary_binaire_insuffisance_cardiaque ~ "Insuffisance cardiaque",
    primary_binaire_coma ~ "Coma",
    primary_binaire_cirrhose ~ "Cirrhose",
    primary_binaire_cancer_du_poumon ~ "Cancer du poumon",
    primary_binaire_cancer_du_colon ~ "Cancer du colon",
    secondary_binaire_choc_septique ~ "Choc septique",
    secondary_binaire_choc_sur_cancer ~ "Choc sur cancer",
    secondary_binaire_coma ~ "Coma",
    secondary_binaire_cirrhose ~ "Cirrhose",
    secondary_binaire_cancer_du_poumon ~ "Cancer du poumon",
    secondary_binaire_cancer_du_colon ~ "Cancer du colon",
    comorbidity_cardiovascular ~ "Cardiopathie",
    comorbidity_congestive_heart ~ "Insuffisance cardiaque congestive",
    comorbidity_myocardial_infarction ~ "Infarctus du myocarde",
    comorbidity_chronic_pulmonary ~ "Maladie pulmonaire chronique",
    comorbidity_renal ~ "Insuffisance rénale",
    comorbidity_liver ~ "Insuffisance hépatique",
    comorbidity_upper_gi_bleeding ~ "Saignement GI supérieur",
    comorbidity_dementia ~ "Démence",
    comorbidity_psych ~ "Psychologique",
    comorbidity_malignancy ~ "Malignité",
    comorbidity_immunosuppression ~ "Immunosuppression",
    comorbidity_transfer ~ "Transfert",
    diagnosis_respiratory ~ "Diagnostic respiratoire",
    diagnosis_cardiovascular ~ "Diagnostic cardiovasculaire",
    diagnosis_neurological ~ "Diagnostic neurologique",
    diagnosis_gastrointestinal ~ "Diagnostic gastro-intestinal",
    diagnosis_renal ~ "Diagnostic rénal",
    diagnosis_metabolic ~ "Diagnostic métabolique",
    diagnosis_hematologic ~ "Diagnostic hématologique",
    diagnosis_sepsis ~ "Diagnostic sepsis",
    diagnosis_trauma ~ "Diagnostic traumatique",
    diagnosis_orthopedic ~ "Diagnostic orthopédique",
    cancer_YN ~ "Cancer (Oui/Non)",
    cancer ~ "Type de cancer",
    weight ~ "Poids",
    mean_blood_pressure ~ "Pression artérielle moyenne",
    heart_rate ~ "Fréquence cardiaque",
    respiratory_rate ~ "Fréquence respiratoire",
    temperature ~ "Température",
    pa_fi_ratio ~ "Ratio Pa/FI",
    urine_output ~ "Diurèse",
```

```r
    wbc ~ "Globules blancs",
    albumin ~ "Albumine",
    hematocrit ~ "Hématocrite",
    bilirubin ~ "Bilirubine",
    creatinine ~ "Créatinine",
    sodium ~ "Sodium",
    potassium ~ "Potassium",
    paco2 ~ "PaCO2",
    ph ~ "pH"
  ),
  type = list(adl_score ~ "continuous")
)

#mise en forme du tableau pour rendu quarto vers pdf
baseline_comparison_table <- baseline_comparison_table |>
  gtsummary::add_p(test = list(gtsummary::all_continuous() ~ "t.test")) |>
  gtsummary::modify_header(label = "**Variable**")
tb <- baseline_comparison_table$table_body
tb$.pos <- seq_len(nrow(tb))
section <- unname(var_to_section[tb$variable])
mask <- tb$row_type == "label" & !is.na(section)
first_pos <- tapply(tb$.pos[mask], section[mask], min)
first_pos <- first_pos[order(first_pos)]
sections <- names(first_pos)
pos_cat <- as.numeric(first_pos) - 0.5
template <- tb[1, , drop = FALSE]
template[,] <- NA
stat_cols <- grep("^stat_", names(tb), value = TRUE)
cat_rows <- template[rep(1, length(sections)), , drop = FALSE]
cat_rows$.pos <- pos_cat
cat_rows$row_type <- "category"
cat_rows$label <- sections
cat_rows$variable <- paste0("cat__", make.names(sections))
cat_rows[, stat_cols] <- ""
cat_rows$p.value <- NA_real_
out <- base::rbind(tb, cat_rows)
out <- out[order(out$.pos), , drop = FALSE]
out$.pos <- NULL
baseline_comparison_table$table_body <- out
baseline_comparison_table <- gtsummary::modify_table_styling(
  baseline_comparison_table, columns = "label", rows = row_type == "category", text_format = "bold"
)
baseline_comparison_table <- gtsummary::modify_table_styling(
  baseline_comparison_table, columns = "label", rows = row_type == "category", text_format = "italic"
)
# affichage du tableau pour quarto vers pdf
baseline_comparison_table |>
  gtsummary::as_kable_extra(booktabs = TRUE, longtable = TRUE) |>
  kableExtra::kable_styling(
    font_size = 8,
    latex_options = c("repeat_header", "scale_down")
  ) |>
  kableExtra::row_spec(
    which(baseline_comparison_table$table_body$row_type == "category"),
    bold = TRUE,
    italic = TRUE
  )

# avec bal.tab et love.plot()
# création d'un objet de balance pour les variables basales
balance_baseline <- bal.tab(
  x = as.formula(paste("rhc ~", paste(cols_to_include_baseline, collapse = " + "))),
  data = df,
  estimand = "ATE"
)

# Retirer les lignes de missingness (":<NA>") sans changer les SMD des vraies covariables
balance_baseline_clean <- balance_baseline
if (!is.null(balance_baseline_clean$Balance)) {
  keep <- !grepl(":<NA>$", rownames(balance_baseline_clean$Balance))
  balance_baseline_clean$Balance <- balance_baseline_clean$Balance[keep, , drop = FALSE]
}

#labels pour lisibilité (on reprend les labels du tableau comparatif)
labels_love_plot <- desc
```

```r
# création du love plot pour les variables basales
love_plot_baseline <- cobalt::love.plot(
  balance_baseline_clean,
  threshold = 0.1,
  var.order = "unadjusted",
  abs = TRUE,
  drop.missing = TRUE,
  line = TRUE,
  colors = c(nord::nord("aurora")[1], nord::nord("aurora")[4]),
  var.names = labels_love_plot
)
print(love_plot_baseline)

# identification des variables avec SMD > 0.1 en valeur absolue
imbalanced_vars <- rownames(balance_baseline_clean$Balance)[abs(balance_baseline_clean$Balance$Diff.Un) >
     0.1]
smd_summary_df <- data.frame(
  `Variable` = imbalanced_vars,
  `SMD` = abs(round(balance_baseline_clean$Balance[imbalanced_vars, "Diff.Un"], 3))
)
knitr::kable(smd_summary_df, booktabs = TRUE)

# imputation par la médiane pour les variables score ADL et diurèse
df_imputed <- df
df_imputed$adl_score[is.na(df_imputed$adl_score)] <- median(df_imputed$adl_score, na.rm = TRUE)
df_imputed$urine_output[is.na(df_imputed$urine_output)] <- median(df_imputed$urine_output, na.rm = TRUE)
#vérification de l'imputation
sum(is.na(df_imputed$adl_score))
sum(is.na(df_imputed$urine_output))
sum(is.na(df_imputed))

# calcul du score de propension avec les variables sélectionnées
df_imputed$rhc <- factor(df_imputed$rhc)

vars_propension <- c(
  "age", "sex", "race", "education_years", "income", "insurance_class",
  "primary_disease_category", "secondary_disease_category",
  grep("^diagnosis_", names(df_imputed), value = TRUE),
  grep("^comorbidity_", names(df_imputed), value = TRUE),
  "adl_score", "DASI_score", "dnr_status", "cancer",
  "survival_probability_2mths", "apache_score", "glasgow_score",
  "weight", "temperature", "mean_blood_pressure", "respiratory_rate", "heart_rate", "pa_fi_ratio", "paco2",
      "ph", "wbc", "hematocrit", "sodium", "potassium", "creatinine", "bilirubin", "albumin", "urine_output"
      )

formula_propension <- paste("rhc ~", paste(vars_propension, collapse = " + "))

#estimation du score de propension
set.seed(123) # pour la reproductibilité
score_propension <- glm(
  formula = as.formula(formula_propension),
  data = df_imputed,
  family = binomial()
)
# ajout du score de propension dans le dataframe
df_imputed$score_propension <- predict(score_propension, type = "response")

# appariement 1:1 sans remplacement avec un caliper de 0.2*SD du score de propension
library(MatchIt)
matchit_out <- MatchIt::matchit(
  formula = as.formula(formula_propension),
  data = df_imputed,
  method = "nearest",
  caliper = 0.2 * sd(df_imputed$score_propension),
  ratio = 1,
  replace = FALSE
)
# création du dataframe apparié
df_matched <- match.data(matchit_out)
# vérification de la taille des groupes appariés
table(df_matched$rhc)

density_plot <- cobalt::bal.plot(
  matchit_out,
  var.name = "distance",
  which = "both",
  type = "density",
```

```r
  colors = c(nord::nord("aurora")[1], nord::nord("aurora")[4]),
  xlab = "Score de propension",
  ylab = "Densité",
  title = "Distribution du score de propension avant et après appariement"
)
print(density_plot)

labels_love_plot_matched <- desc
love_plot_matched <- love.plot(
  matchit_out,
  stats = "mean.diffs",
  s.d.denom = "pooled",
  binary = "std",
  threshold = 0.1,
  var.order = "unadjusted",
  abs = TRUE,
  line = TRUE,
  var.names = labels_love_plot_matched,
  colors = c(nord("aurora")[1], nord("aurora")[4])
)
print(love_plot_matched)

balance <- cobalt::bal.tab(matchit_out, un = TRUE)$Balance

tab <- data.frame(
  Avant_appariement = sum(abs(balance$Diff.Un) > 0.1, na.rm = TRUE),
  Apres_appariement = sum(abs(balance$Diff.Adj) > 0.1, na.rm = TRUE)
)

knitr::kable(
  tab,
  format = "latex",
  booktabs = TRUE,
  row.names = FALSE
)

# avec pourcentage de décès à 30 jours et à 180 jours dans les groupes R
# utilisation de tbl_summary de gtsummary pour faire un tableau comparatif des décès à 30 jours et à 180
     jours entre les groupes RHC vs non-RHC
summary_table <- df_matched %>%
  select(rhc, death_30d, death_180d) %>%
  tbl_summary(
    by = rhc,
    statistic = list(
      death_30d ~ "{n} ({p}%)",
      death_180d ~ "{n} ({p}%)"
    ),
    label = list(
      death_30d ~ "Décès à 30 jours",
      death_180d ~ "Décès à 180 jours"
    ),
    missing = "no"
  ) %>%
  add_p() %>%
  modify_header(label = "**Variable**")
summary_table

# calcul de l'OR pour le décès à 30 jours
or_30d <- epitools::oddsratio(
  x = table(df_matched$rhc, df_matched$death_30d),
  method = "wald",
  conf.level = 0.95
)
# calcul de l'OR pour le décès à 180 jours
or_180d <- epitools::oddsratio(
  x = table(df_matched$rhc, df_matched$death_180d),
  method = "wald",
  conf.level = 0.95
)
# création d'un tableau récapitulatif des OR
or_summary_df <- data.frame(
  `Critère` = c("Décès à 30 jours", "Décès à 180 jours"),
  `OR` = c(round(or_30d$measure[2, "estimate"], 2), round(or_180d$measure[2, "estimate"], 2)),
  "IC 95%" = c(
    paste0("(", round(or_30d$measure[2, "lower"], 2), ", ", round(or_30d$measure[2, "upper"], 2), ")"),
    paste0("(", round(or_180d$measure[2, "lower"], 2), ", ", round(or_180d$measure[2, "upper"], 2), ")")
```

```r
  ),
  check.names = FALSE
)
knitr::kable(or_summary_df, booktabs = TRUE)

# conversion des dates en format Date
df_matched$date_admission <- as.Date(df_matched$date_admission)
df_matched$date_death <- as.Date(df_matched$date_death)
df_matched$date_last_news <- as.Date(df_matched$date_last_news)


# Recalcul des temps à partir des dates (suivi "complet")
df_matched$time_to_death <- as.numeric(df_matched$date_death - df_matched$date_admission)
df_matched$time_to_last_news <- as.numeric(df_matched$date_last_news - df_matched$date_admission)

df_matched$time_to_death

# Événement "décès" selon la présence d'une date de décès
df_matched$event_death <- as.integer(!is.na(df_matched$date_death))
# Temps de suivi complet (décès -> date_death, sinon -> date_last_news)
df_matched$followup_time <- df_matched$time_to_last_news

# Si décès, temps de suivi = temps jusqu'au décès
df_matched$followup_time[df_matched$event_death == 1] <- df_matched$time_to_death[df_matched$event_death ==
     1]

# Temps d'inclusion : prend le minimum entre le temps de suivi et 180 jours (donc censure après 180 jours)
df_matched$survival_time_180d <- pmin(df_matched$followup_time, 180)

# Événement "décès" à 180 jours : vaut 1 si décès ET temps jusqu'au décès <= 180 jours
df_matched$event_180d <- as.integer(df_matched$event_death == 1 & df_matched$time_to_death <= 180)

# Temps négatifs -> NA
df_matched$survival_time_180d[df_matched$survival_time_180d < 0] <- NA

# création de l'objet de survie
surv_object <- Surv(time = df_matched$survival_time_180d, event = df_matched$event_180d)
# ajustement du modèle de survie de Kaplan-Meier
km_fit <- survfit(surv_object ~ rhc, data = df_matched)
# affichage du graphique de survie
km_plot <- ggsurvplot(
  km_fit,
  data = df_matched,
  pval = TRUE,
  conf.int = TRUE,
  risk.table = TRUE,
  risk.table.height = 0.2,
  risk.table.fontsize = 3.2,
  break.time.by = 30,
  xlim = c(0, 180),
  legend.labs = c("Non-RHC", "RHC"),
  legend.title = "Groupe",
  xlab = "Temps (jours)",
  ylab = "Probabilité de survie",
  title = "Courbe de survie de Kaplan-Meier selon le RHC",
  palette = c(nord::nord("aurora")[1], nord::nord("aurora")[4])
)
print(km_plot)

# test du log-rank conventionnel
logrank_conventional <- survdiff(surv_object ~ rhc, data = df_matched)
p_logrank_conventional <- 1 - pchisq(logrank_conventional$chisq, df = 1)
# test du log-rank stratifié sur les paires
logrank_stratified <- survdiff(
  surv_object ~ rhc + strata(subclass),
  data = df_matched
)

p_logrank_stratified <- 1 - pchisq(logrank_stratified$chisq, df = 1)

logrank_results <- data.frame(
  Test = c("Log-rank conventionnel", "Log-rank stratifié"),
  p_value = c(p_logrank_conventional, p_logrank_stratified)
)

knitr::kable(logrank_results, booktabs = TRUE)

# ajustement du modèle de Cox avec variance robuste et cluster sur les paires appariées
```

```r
cox_model <- coxph(
  surv_object ~ rhc,
  data = df_matched,
  cluster = subclass
)
#affichage des résultats du modèle de Cox
cox_summary <- summary(cox_model)
cox_results <- data.frame(
  Variable = rownames(cox_summary$coefficients),
  HR = round(cox_summary$coefficients[, "exp(coef)"], 2),
  "IC 95%" = paste0("(", round(cox_summary$conf.int[, "lower .95"], 2), ", ", round(cox_summary$conf.int[, "
      upper .95"], 2), ")"),
  p_value = format.pval(cox_summary$coefficients[, "Pr(>|z|)"], digits = 3, eps = 0.001),
  row.names = NULL
)
cox_results$Variable <- "RHC vs No RHC"
knitr::kable(cox_results, booktabs = TRUE)

# vérification de l'hypothèse de proportionalité des risques avec les résidus de Schoenfeld
cox_zph <- cox.zph(cox_model)
plot(cox_zph)

# ajustement du modèle de Cox multivarié
cox_multivariate_model <- coxph(
  Surv(survival_time_180d, event_180d) ~ rhc + age + sex + race + education_years + income + insurance_class
      +
    primary_disease_category + secondary_disease_category +
    diagnosis_respiratory + diagnosis_cardiovascular + diagnosis_neurological +
    diagnosis_gastrointestinal + diagnosis_renal + diagnosis_metabolic +
    diagnosis_hematologic + diagnosis_sepsis + diagnosis_trauma +
    diagnosis_orthopedic + adl_score + DASI_score + dnr_status + cancer +
    survival_probability_2mths + apache_score + glasgow_score +
    weight + temperature + mean_blood_pressure + respiratory_rate +
    heart_rate + pa_fi_ratio + paco2 + ph + wbc + hematocrit +
    sodium + potassium + creatinine + bilirubin + albumin + comorbidity_cardiovascular + comorbidity_
        congestive_heart +
    comorbidity_dementia + comorbidity_psych + comorbidity_chronic_pulmonary + comorbidity_renal +
        comorbidity_liver + comorbidity_upper_gi_bleeding +
    comorbidity_malignancy + comorbidity_immunosuppression + comorbidity_transfer + comorbidity_myocardial_
        infarction +
    urine_output,
  data = df_imputed
)
#extraction de l'OR pour le RHC et de son intervalle de confiance
cox_multivariate_summary <- summary(cox_multivariate_model)
cox_multivariate_results <- data.frame(
  Variable = rownames(cox_multivariate_summary$coefficients),
  HR = round(cox_multivariate_summary$coefficients[, "exp(coef)"], 2),
  IC95 = paste0("(", round(cox_multivariate_summary$conf.int[, "lower .95"], 2), ", ", round(cox_
      multivariate_summary$conf.int[, "upper .95"], 2), ")"),
  p_value = format.pval(cox_multivariate_summary$coefficients[, "Pr(>|z|)"], digits = 3, eps = 0.001),
  row.names = NULL
)
cox_multivariate_results <- cox_multivariate_results[cox_multivariate_results$Variable == "rhcRHC", ]


cox_multivariate_results$Variable <- "RHC vs No RHC"

knitr::kable(cox_multivariate_results, booktabs = TRUE)

# calcul des p-values pour les variables basales après appariement
df_baseline_post_matching <- df_matched[, unique(c("rhc", cols_to_include_baseline))]

# Forcer l'affichage des variables binaires sur une seule ligne (compte du "Yes"),
binary_var_names <- setdiff(
  names(df_baseline_post_matching)[
    grepl("^(primary_binaire_|secondary_binaire_|comorbidity_|diagnosis_)|^cancer_YN$", names(df_baseline_
        post_matching))
  ],
  "rhc"
)

df_baseline_post_matching[binary_var_names] <- lapply(df_baseline_post_matching[binary_var_names], function(
    x) {
  x_chr <- as.character(x)
  x_chr <- trimws(x_chr)
  x_chr <- dplyr::case_when(
```

```r
    is.na(x_chr) ~ NA_character_,
    x_chr %in% c("1", "TRUE", "True", "true", "Yes", "YES", "Oui", "OUI") ~ "Yes",
    x_chr %in% c("0", "FALSE", "False", "false", "No", "NO", "Non", "NON") ~ "No",
    TRUE ~ x_chr
  )
  factor(x_chr, levels = c("Yes", "No"))
})

# répartition des variables en sous groupes pour la mise en forme du tableau
primary_binaire_columns <- grep("^primary_binaire_", primary_columns, value = TRUE)
secondary_binaire_columns <- grep("^secondary_binaire_", primary_columns, value = TRUE)

var_to_section <- c(
  stats::setNames(rep("Démographie / socio-économique", length(vars_demo)), vars_demo),
  stats::setNames(rep("Statut fonctionnel / scores", length(vars_scores)), vars_scores),
  stats::setNames(rep("Comorbidités", length(vars_comorb)), vars_comorb),
  stats::setNames(rep("Diagnostic principal (CAT1)", length(primary_binaire_columns)), primary_binaire_
      columns),
  stats::setNames(rep("Comorbidité principale (CAT2)", length(secondary_binaire_columns)), secondary_binaire
      _columns),
  stats::setNames(rep("Diagnostics", length(vars_diag_other)), vars_diag_other),
  stats::setNames(rep("Cancer", length(vars_cancer)), vars_cancer),
  stats::setNames(rep("Paramètres cliniques", length(vars_clinical)), vars_clinical),
  stats::setNames(rep("Biologie", length(vars_bio)), vars_bio)
)

# Tableau avec gtsummary
baseline_comparison_table <- gtsummary::tbl_summary(
  df_baseline_post_matching,
  by = "rhc",
  missing = "no",
  statistic = list(
    gtsummary::all_continuous() ~ "{mean} ({sd})",
    gtsummary::all_dichotomous() ~ "{n} ({p}%)",
    gtsummary::all_categorical() ~ "{n} ({p}%)"
  ),
  label = list(
    age ~ "Âge",
    sex ~ "Sexe",
    race ~ "Ethnie",
    education_years ~ "Années d'éducation",
    income ~ "Revenu",
    insurance_class ~ "Classe d'assurance",
    adl_score ~ "Score ADL",
    DASI_score ~ "Score DASI",
    glasgow_score ~ "Score Coma",
    apache_score ~ "Score APACHE",
    dnr_status ~ "Statut DNR",
    primary_binaire_BPCO ~ "BPCO",
    primary_binaire_choc_septique ~ "Choc septique",
    primary_binaire_choc_sur_cancer ~ "Choc sur cancer",
    primary_binaire_insuffisance_renale_aigue ~ "Insuffisance rénale aiguë",
    primary_binaire_insuffisance_cardiaque ~ "Insuffisance cardiaque",
    primary_binaire_coma ~ "Coma",
    primary_binaire_cirrhose ~ "Cirrhose",
    primary_binaire_cancer_du_poumon ~ "Cancer du poumon",
    primary_binaire_cancer_du_colon ~ "Cancer du colon",
    secondary_binaire_choc_septique ~ "Choc septique",
    secondary_binaire_choc_sur_cancer ~ "Choc sur cancer",
    secondary_binaire_coma ~ "Coma",
    secondary_binaire_cirrhose ~ "Cirrhose",
    secondary_binaire_cancer_du_poumon ~ "Cancer du poumon",
    secondary_binaire_cancer_du_colon ~ "Cancer du colon",
    comorbidity_cardiovascular ~ "Cardiopathie",
    comorbidity_congestive_heart ~ "Insuffisance cardiaque congestive",
    comorbidity_myocardial_infarction ~ "Infarctus du myocarde",
    comorbidity_chronic_pulmonary ~ "Maladie pulmonaire chronique",
    comorbidity_renal ~ "Insuffisance rénale",
    comorbidity_liver ~ "Insuffisance hépatique",
    comorbidity_upper_gi_bleeding ~ "Saignement GI supérieur",
    comorbidity_dementia ~ "Démence",
    comorbidity_psych ~ "Psychologique",
    comorbidity_malignancy ~ "Malignité",
    comorbidity_immunosuppression ~ "Immunosuppression",
    comorbidity_transfer ~ "Transfert",
    diagnosis_respiratory ~ "Diagnostic respiratoire",
```

```r
    diagnosis_cardiovascular ~ "Diagnostic cardiovasculaire",
    diagnosis_neurological ~ "Diagnostic neurologique",
    diagnosis_gastrointestinal ~ "Diagnostic gastro-intestinal",
    diagnosis_renal ~ "Diagnostic rénal",
    diagnosis_metabolic ~ "Diagnostic métabolique",
    diagnosis_hematologic ~ "Diagnostic hématologique",
    diagnosis_sepsis ~ "Diagnostic sepsis",
    diagnosis_trauma ~ "Diagnostic traumatique",
    diagnosis_orthopedic ~ "Diagnostic orthopédique",
    cancer_YN ~ "Cancer (Oui/Non)",
    cancer ~ "Type de cancer",
    weight ~ "Poids",
    mean_blood_pressure ~ "Pression artérielle moyenne",
    heart_rate ~ "Fréquence cardiaque",
    respiratory_rate ~ "Fréquence respiratoire",
    temperature ~ "Température",
    pa_fi_ratio ~ "Ratio Pa/FI",
    urine_output ~ "Diurèse",
    wbc ~ "Globules blancs",
    albumin ~ "Albumine",
    hematocrit ~ "Hématocrite",
    bilirubin ~ "Bilirubine",
    creatinine ~ "Créatinine",
    sodium ~ "Sodium",
    potassium ~ "Potassium",
    paco2 ~ "PaCO2",
    ph ~ "pH"
  ),
  type = list(adl_score ~ "continuous", all_of(binary_var_names) ~ "dichotomous"),
  value = list(all_of(binary_var_names) ~ "Yes")
)

#mise en forme du tableau pour rendu quarto vers pdf
baseline_comparison_table <- baseline_comparison_table |>
  gtsummary::add_p(test = list(gtsummary::all_continuous() ~ "t.test")) |>
  gtsummary::modify_header(label = "**Variable**")

tb <- baseline_comparison_table$table_body
tb$.pos <- seq_len(nrow(tb))

section <- unname(var_to_section[tb$variable])
mask <- tb$row_type == "label" & !is.na(section)

first_pos <- tapply(tb$.pos[mask], section[mask], min)
first_pos <- first_pos[order(first_pos)]

sections <- names(first_pos)
pos_cat <- as.numeric(first_pos) - 0.5

template <- tb[1, , drop = FALSE]
template[,] <- NA

stat_cols <- grep("^stat_", names(tb), value = TRUE)

cat_rows <- template[rep(1, length(sections)), , drop = FALSE]
cat_rows$.pos <- pos_cat
cat_rows$row_type <- "category"
cat_rows$label <- sections
cat_rows$variable <- paste0("cat__", make.names(sections))
cat_rows[, stat_cols] <- ""
cat_rows$p.value <- NA_real_

out <- base::rbind(tb, cat_rows)
out <- out[order(out$.pos), , drop = FALSE]
out$.pos <- NULL

baseline_comparison_table$table_body <- out
baseline_comparison_table <- gtsummary::modify_table_styling(
  baseline_comparison_table, columns = "label", rows = row_type == "category", text_format = "bold"
)
baseline_comparison_table <- gtsummary::modify_table_styling(
  baseline_comparison_table, columns = "label", rows = row_type == "category", text_format = "italic"
)

# affichage du tableau pour quarto vers pdf
baseline_comparison_table |>
  gtsummary::as_kable_extra(booktabs = TRUE, longtable = TRUE) |>
  kableExtra::kable_styling(
```

```
    font_size = 8,
    latex_options = c("repeat_header", "scale_down")
  ) |>
  kableExtra::row_spec(
    which(baseline_comparison_table$table_body$row_type == "category"),
    bold = TRUE,
    italic = TRUE
  )


#insérer le code à la fin du fichier

# lire le fichier code genere
code <- readLines("all_chunks_code.R", warn = FALSE)

    code_wrapped <- code

    if (knitr::is_latex_output()) {
  code_safe <- code_wrapped
  code_safe <- gsub("`([^"]*’[']][^"]*)`", "\"\\1\"", code_safe, perl = TRUE)
  code_safe <- gsub("`([^`]*\\s+[^`]*)`", "\"\\1\"", code_safe, perl = TRUE)
  code_safe <- gsub(
     "\\\\(begin|end)\\{lstlisting\\}",
     "\\\\textbackslash \\1{lstlisting}",
     code_safe
  )
  cat("\\textbackslash begin{lstlisting}\n")
  cat(code_safe, sep = "\n")
  cat("\n\\textbackslash end{lstlisting}\n")
    } else {
    cat("```r\n")
    cat(code_wrapped, sep = "\n")
    cat("\n```")
}
```